

Glossário sobre Indicadores e Índices de Secas e Inteligência Artificial

Ricardo S. Oyarzabal (Cemaden)

Leonardo B. L. Santos (Cemaden)

Conteúdo

1	Introdução	2
2	Indicadores de Secas	4
2.1	Entradas para Índices de Secas e Modelos de (AM)	5
3	Índices de Seca para cada tipo Seca	8
3.1	Aplicação	8
3.1.1	Seca Meteorológica	8
3.1.2	Seca Agrícola	10
3.1.3	Seca Hidrológica	11
3.2	Dados de Sensoriamento Remoto	12
3.3	Índices Compostos ou Modelados	13
4	Métodos de aprendizado de máquina usados para previsão de seca	14
4.1	Classe ANN	14
4.2	Classe DT	16
4.3	Classe Ensemble	16
4.4	Classe ANFIS	16
4.5	Classe ARIMA	17
4.6	Classe SVM	17
4.7	Outras classes	17
5	Conclusão	18
	Glossário	18

Glossário sobre Índices e Indicadores de Secas e Inteligência Artificial

Resumo

O estudo das secas desempenha um papel fundamental no planejamento e gerenciamento de recursos hídricos. Este glossário reúne e organiza definições, conceitos, indicadores e índices relacionados às secas, além de abordar metodologias de inteligência artificial aplicadas à previsão e ao monitoramento desses fenômenos. O objetivo deste trabalho é disseminar o conhecimento científico e evidenciar a ampliação do conjunto de metodologias e ferramentas disponíveis para o monitoramento e avaliação dos impactos das secas, contribuindo para a gestão de riscos e a tomada de decisões informadas. Esta iniciativa é promovida pelo [Cemaden](#), cuja missão é produzir conhecimento científico e tecnológico sobre ameaças, processos e vulnerabilidades associados às secas e seus impactos, fornecendo subsídios essenciais para a sociedade e para os tomadores de decisão. Esta é a primeira versão do glossário, que busca consolidar e expandir o entendimento sobre o tema, integrando abordagens tradicionais e inovações tecnológicas, como o uso de técnicas de aprendizado de máquina e inteligência artificial.

Palavras-chave: Secas, Cemaden, Índices, Indicadores, Inteligência Artificial.

1 Introdução

As secas têm características diferentes no espaço e no tempo: a [Seca Meteorológica](#) começa com uma precipitação deficitária persistente que é menor do que a média de longo prazo em uma região e pode evoluir para uma [Seca Agrícola](#) se sua condição começar a afetar a água do solo (Ashok K Mishra e Singh [2010a](#); D. A. Wilhite et al. [2017](#); Loon [2015](#)). Déicits prolongados de precipitação, geralmente em escalas de tempo que excedem seis meses, impactam os níveis dos rios e reservatórios, levando à [Seca Hidrológica](#) (Loon [2015](#)).

Os indicadores de seca são variáveis climáticas e hidrológicas dire-

tamente observadas, como [Precipitação \(P\)](#), [Umidade do Solo \(US\)](#) e [Descarga ou vazão \(Q\)](#) dos rios, que refletem a disponibilidade hídrica em uma região (D. A. Wilhite [2000](#); Svoboda e Fuchs [2016](#)). Já os índices de seca são métricas derivadas desses indicadores, combinando múltiplas variáveis para quantificar a severidade, duração e impacto da seca (Zargar et al. [2011](#)). Por exemplo, diferentes índices são empregados para caracterizar distintos tipos de secas: o Índice Padronizado de Precipitação [Standardized Precipitation Index \(SPI\)](#) é amplamente utilizado para secas meteorológicas (McKee, Doesken e Kleist [1993](#)); o

Índice de Déficit de Umidade do Solo [Soil Moisture Deficit Index \(SMDI\)](#) auxilia no monitoramento da seca agrícola (Narasimhan e Srinivasan 2007); e o Índice de Severidade de Seca Hidrológica [Streamflow Drought Index \(SDI\)](#) avalia impactos em sistemas hídricos (Nuhfer et al. 2020). A escolha do índice adequado depende do contexto da análise e dos objetivos do monitoramento (D. A. Wilhite 2011).

Prever a severidade da seca, ou seja, a [Magnitude](#), bem como desenvolver técnicas adequadas para prever o [Início](#) e o [Fim](#) de um período de secas ainda é desafiador. Exemplos específicos de métodos já explorados para prever aspectos da seca incluem análise de regressão (Liu e Juárez 2001) e análise de séries temporais (A. Mishra e Desai 2005). Os métodos tradicionais de avaliação de seca dependem de dados de precipitação de estações meteorológicas terrestres, que geralmente são esparsas ou distribuídas de forma desigual, especialmente em áreas remotas ou mal instrumentadas. Essa limitação dificulta o monitoramento eficaz das condições de seca em regiões amplas e diversas. O [Sensoriamento Remoto \(SR\)](#), no entanto, supera essas restrições ao fornecer observações consistentes, espacialmente extensas e temporalmente frequentes. Usando sensores baseados em [Satélites](#), o [SR](#) captura as características físicas da superfície da Terra por meio de medições de radiação refletida e emitida, cobrindo espectros visíveis e infravermelhos (VIS/IR). Satélites geoestacionários equipados com radiômetros multiespectrais, por exemplo, oferecem informações vitais relacionadas à seca sobre [Precipitação \(P\)](#), [Umidade do Solo \(US\)](#) e [Evapotranspiração](#) (AghaKouchak et al. 2015; McCabe et al. 2017).

Técnicas de [Inteligência Artificial \(IA\)](#) também podem modelar funções não lineares complexas sem exigir conhecimento profundo do fenômeno estudado (Rajaei, Ebrahimi e Nourani 2019). Nos últimos anos, mais e mais pesquisas têm sido feitas usando técnicas de [Aprendizado de Máquina \(AM\)](#) para prever secas em várias escalas espaço-temporais. Essas técnicas permitem treinamento e aprendizado usando múltiplos bancos de dados de longo prazo. Esse aprendizado pode então ser aplicado para identificar condições de seca antecedentes em

uma região, conforme investigado em (Qi Zhang et al. 2023; Yaseen et al. 2021). [AM](#) é uma área da [IA](#) dedicada ao desenvolvimento de métodos que permitem que os computadores resolvam tarefas específicas aprendendo diretamente e somente a partir de dados (Soori, Arezoo e Dastres 2023).

O uso de técnicas de [Aprendizado de Máquina \(AM\)](#) em ciências da terra já está bem estabelecido, principalmente porque sistemas construídos com essas técnicas contribuem para reduzir incertezas e permitem tempos de previsão mais rápidos (L. Chen et al. 2023)). Um exemplo é a classificação do uso do solo, que foi usada no programa de satélite de observação da Terra LandSat. Atualmente, métodos como [K-means](#), evoluíram para métodos mais sofisticados que incluem informações de contexto, conhecimento externo e detecção de objetos (Phiri e Morgenroth 2017).

O número de artigos científicos relacionados à previsão de seca e métodos de [AM](#) aumentou nos últimos anos, mostrando que este é um tópico potencial para pesquisas futuras. Conforme mostra a Figura 1, este aumento traz novas maneiras de analisar padrões de seca no espaço e no tempo e abordagens inovadoras para a previsão de seca. Os métodos de [AM](#) permitem que novos padrões de seca sejam identificados, especialmente quando se considera as mudanças climáticas, que vêm alterando os padrões conhecidos de eventos extremos ao redor do mundo (Oyarzabal e L. Santos 2025).

A previsão de seca subsazonal para sazonal (S2S) usando métodos de [Aprendizado de Máquina \(AM\)](#) pode ser especialmente benéfica em regiões onde modelos climáticos complexos apresentam desempenho ruim. Por décadas, previsões sazonais de seca ou chuvas excessivas têm se baseado em modelos que acoplam os sistemas físicos da atmosfera e dos oceanos (Johansson et al. 1998; Briggs e Wilks 1996; Goddard et al. 2001).

Em teoria, técnicas de [AM](#) podem melhorar a previsão de S2S para essas regiões específicas, integrando-as com dados históricos de fontes potenciais de previsibilidade, como umidade do solo ou a Oscilação

Quase Bienal (Lindzen e James R Holton 1968; James R Holton e Lindzen 1972; Baldwin et al. 2001). Além disso, técnicas de IA têm algumas vantagens sobre as abordagens estatísticas tradicionais. Entre elas está a capacidade de lidar com dados de entrada esparsos e ruidosos (Wegmann e Jaume-Santero 2023).




Figura 1: Representação em forma de barra de frequências relativas ao tipo seca estudada aplicando modelos de Aprendizado de Máquina mais utilizada na literatura.

Assim como as previsões meteorológicas sazonais, a previsão de eventos extremos e projeções climáticas de longo prazo continua sendo um desafio (Reichstein et al. 2019). As mudanças climáticas interrompem o comportamento histórico nas variáveis hidrometeorológicas (por exemplo, aumento da temperatura e mudanças na precipitação), aumentando a variabilidade, incluindo eventos climáticos extremos mais frequentes (Leal Filho et al. 2022). No contexto da seca, as mudanças climáticas estão mudando regiões propensas à seca e alterando a distribuição espacial do estresse hídrico (IPCC 2023), que pode criar mecanismos de feedback (por exemplo, seca prolongada reduzindo a vegetação, o que por sua vez afeta os padrões de precipitação e temperatura) que introduzem complexidades não lineares.

A previsão eficaz da seca no contexto das mudanças climáticas requer

a integração de diversos dados de disciplinas como clima e hidrologia. Algoritmos tradicionais de AM podem capturar relações não lineares; no entanto, técnicas avançadas como Deep Learning (DL) são frequentemente mais eficazes na modelagem dessas dependências e mecanismos de feedback. Elas também podem se adaptar a mudanças em padrões e variabilidade. Neste contexto, vários estudos têm sugerido combinar técnicas de Inteligência Artificial (IA) e Aprendizado de Máquina (AM) com modelos físicos para melhorar as previsões de eventos extremos (Reichstein et al. 2019; Huntingford et al. 2019).

Este glossário foi desenvolvido para apoiar o entendimento dos principais termos relacionados a indicadores de secas e técnicas de Inteligência Artificial (IA) aplicadas em estudos relacionados à secas. Na Seção 2, são apresentados os principais indicadores e variáveis que compõem os índices de secas. A Seção 3 descreve diversos índices utilizados para caracterizar secas meteorológicas, agrícolas e hidrológicas, além de índices baseados em sensoriamento remoto e índices compostos. Por fim, na Seção 4, abordamos diferentes classes de métodos de Aprendizado de Máquina (AM) empregados em pesquisas voltadas para a previsão de secas.

2 Indicadores de Secas

Os indicadores de seca são variáveis essenciais para a caracterização e monitoramento desses eventos extremos. A partir deles, é possível quantificar a severidade da seca e avaliar seus impactos em diferentes setores, como agricultura, abastecimento de água e geração de energia. Esses indicadores são geralmente derivados de variáveis hidroclimáticas, incluindo precipitação, umidade do solo, vazão dos rios e níveis de água subterrânea (D. A. Wilhite 2000; Svoboda e Fuchs 2016).

Diferentes estágios da seca exigem diferentes indicadores para sua caracterização. A Área Afetada é a extensão geográfica da seca, expressa em área total ou percentual de uma região impactada. Quanto maior a área afetada, maior a exposição de ativos econômicos e ambientais

aos efeitos da seca. **Frequência** é o número de eventos de seca dentro de um determinado período de tempo. Secas mais frequentes podem resultar em impactos acumulativos e prolongados nos ecossistemas e na sociedade. A **Magnitude** está relacionada ao déficit hídrico total do evento. É calculada pela soma dos desvios absolutos entre os valores do indicador de seca e o limite usado para definir o nível de seca: $S_i = \sum |DI_i| < threshold$. A **Intensidade** representa a gravidade da seca em relação à sua duração, sendo calculada pela magnitude dividida pelo tempo total do evento. Esse indicador auxilia na identificação do potencial geral de impactos da seca (Vogt et al. 2018; Dutra et al. 2014).

A **Duração** é o tempo total do evento de seca, podendo ser medido em dias, meses ou anos. Secas prolongadas possuem maior potencial de propagação ao longo do ciclo hidrológico, podendo gerar impactos secundários significativos. O **Início** indica o momento em que a seca se inicia, ou seja, quando o valor do indicador de seca fica abaixo de um determinado limite. Esse aspecto é fundamental para a gestão da seca, especialmente em períodos de alta demanda hídrica, como o plantio e a floração de culturas agrícolas. A **Interrupção** refere-se ao momento em que os índices meteorológicos voltam ao normal e a umidade do solo começa a se recuperar. O crescimento da vegetação e a recarga dos reservatórios também são sinais de interrupção da seca. O **Fim** representa o retorno das condições naturais à normalidade, incluindo a recuperação da produtividade agrícola e dos ecossistemas, bem como a estabilização das condições socioeconômicas. O **Mês de Pico** é o período no qual o indicador de seca atinge seu menor valor, indicando o momento de maior impacto potencial (Vogt et al. 2018; Sheffield et al. 2014).

2.1 Entradas para Índices de Secas e Modelos de (AM)

Os índices de secas são calculados a partir de variáveis hidroclimáticas fundamentais, como **Precipitação (P)**, **Descarga ou vazão (Q)**, **Tempera-**

tura (T) e **Evapotranspiração**. Essas variáveis não apenas caracterizam as secas, mas também são amplamente utilizadas como entradas em modelos de **Aprendizado de Máquina (AM)** para previsão e monitoramento de secas (Ashok K Mishra e Singh 2010b; Duan e Xiurui Zhang 2022). A escolha adequada dos *inputs* influencia diretamente a precisão dos modelos, sendo essencial compreender sua variabilidade espaço-temporal e relação com os eventos de seca. A Figura 2 apresenta a distribuição percentual das variáveis mais utilizadas em estudos recentes sobre previsão de secas utilizando **AM** (Oyarzabal e L. Santos 2025)).




Figura 2: Um mapa de árvore ilustrando os dados de entrada mais comumente usados em aplicativos de ML para previsão de seca. A área de cada retângulo representa a proporção de uso para cada dado de entrada.

A **Precipitação (P)** é um dos principais *inputs* do sistema hidrológico e representa a quantidade de água que atinge a superfície terrestre na forma de chuva, neve, granizo ou neblina. Conforme mostra a Figura

2, representa quase 43% dos dados de entradas nos modelos de AM utilizados nos estudos de previsão de seca. Esse fenômeno é o fator desencadeador de processos hidrológicos fundamentais, como escoamento superficial direto, infiltração no solo, evaporação, transpiração, recarga de aquíferos e fluxo de base. Devido à sua alta variabilidade espacial e temporal, a Precipitação (P) é um dos principais elementos analisados no monitoramento e previsão de secas. Pequenas mudanças na sua distribuição podem afetar significativamente a disponibilidade hídrica, impactando a agricultura, os ecossistemas e os recursos hídricos. Além disso, é um dado essencial para o planejamento de longo prazo, auxiliando na definição de políticas de gestão de água e mitigação de desastres naturais relacionados à seca (Disaster Risk Reduction (UNDRR) 2021; F. A. M. Silva, C. A. C. d. Santos e R. M. Silva 2015; Mo e Lettenmaier 2016)).

A Precipitação (P) pode ser monitorada por diferentes métodos, como estações pluviométricas, radares meteorológicos e sensoramento remoto via satélite. Estes métodos permitem análises em diferentes escalas, desde eventos locais até tendências climáticas globais. A Medição de chuva pode ser realizada por diferentes tecnologias, sendo as principais os Radares meteorológicos e os Satélites. Os Radares meteorológicos são sensores ativos que utilizam ondas de rádio para detectar e monitorar a precipitação. Eles permitem a localização da chuva, a estimativa de sua intensidade e o rastreamento de seu movimento, sendo amplamente utilizados em previsões meteorológicas e no monitoramento de tempestades severas. Os Satélites, por sua vez, fornecem uma visão abrangente da atmosfera e utilizam diversas técnicas para estimar a taxa de precipitação. A partir de sensores a bordo, podem captar radiação visível, infravermelha e micro-ondas, possibilitando a detecção de nuvens e a inferência de padrões de chuva em escalas globais e regionais.

A Temperatura (T) é uma variável fundamental no sistema climático, influenciando diretamente processos hidrológicos e ecossistêmicos. Como mostra a Figura 2, este indicador é responsável por quase 23% dos *inputs* nos modelos de AM utilizados nos estudos de previsão de seca. A

Temperatura (T) em geral, tende a ser mais elevada nas baixas latitudes e diminui em direção aos polos. No entanto, essa tendência pode ser modificada por fatores como a distribuição de terras e oceanos, a topografia e a cobertura vegetal (J. A. Silva 2008; Mo e Lettenmaier 2016). A Variação da temperatura (ΔT) ocorre em diferentes escalas temporais. A variação diária da temperatura está associada à flutuação da Radiação solar incidente, com máximos geralmente ocorrendo à tarde e mínimos durante a madrugada. Já as Variações sazonais refletem mudanças nos padrões de insolação ao longo do ano, influenciadas pela inclinação do eixo terrestre e pela duração do dia.

A Figura 2 mostra o *input* Evapotranspiração com 4,7% como indicador utilizados nos estudos de previsão de secas aplicando modelos de AM. A Evapotranspiração é o processo combinado de transferência de água para a atmosfera por meio da evaporação da água do solo e da vegetação úmida, além da transpiração das plantas. Esse fenômeno representa a taxa líquida de transporte de vapor d'água da superfície terrestre (continentes e oceanos) para a atmosfera e desempenha um papel fundamental no ciclo hidrológico e no balanço hídrico. A Evapotranspiração influencia diretamente a disponibilidade de água nos ecossistemas, afetando a vazão dos rios, a recarga de aquíferos e o rendimento dos reservatórios. Dessa forma, sua quantificação é essencial para o planejamento e a gestão de recursos hídricos. A fração da água precipitada que contribui para a vazão e a recarga do aquífero é amplamente determinada pela umidade do solo, que pode ser estimada a partir do cálculo da ET desde o último evento de precipitação (Camargo e Sentelhas 2011; Kaur e Sood 2020).

A Evapotranspiração Potencial (ETP) representa a taxa máxima de evapotranspiração que ocorreria em uma superfície completamente coberta por uma vegetação de altura uniforme, sem restrições hídricas e sem efeitos de advecção ou armazenamento de calor. Esse conceito reflete o potencial máximo de perda de água para a atmosfera sob condições ideais, servindo como um importante indicador da capacidade de secamento do clima (Shuttleworth 2006; Thornthwaite 1948). A

ETP é geralmente estimada a partir de dados meteorológicos, mesmo em cenários onde a evapotranspiração real é menor do que o valor potencial. Apesar dessas limitações, a ETP é amplamente utilizada na análise de balanço hídrico, no planejamento agrícola e na gestão de recursos hídricos, auxiliando na compreensão da demanda atmosférica por umidade nas condições ambientais locais (Shuttleworth 2006).

A Umidade Relativa (UR) representa a razão entre a quantidade de vapor d'água presente no ar e a quantidade máxima que o ar pode conter a uma determinada temperatura. É expressa em porcentagem (%) e influencia diretamente os processos de evapotranspiração e formação de nuvens (Lawrence 2005).

Conforme mostra a Figura 2, a Descarga ou vazão (Q) representa 3.8% das entradas de modelos de AM nas pesquisas sobre previsão de seca. A Descarga ou vazão (Q) representa a quantidade de água que escoar através de um curso d'água em um determinado período de tempo. Esse parâmetro é essencial para o monitoramento hidrológico, pois reflete a disponibilidade hídrica e influencia diretamente a gestão de recursos hídricos, geração de energia, abastecimento de água e controle de inundações. A Q pode apresentar grande variação temporal e espacial, sendo influenciada por fatores como precipitação, evapotranspiração, infiltração no solo e intervenções antrópicas, como a construção de represas e a captação de água para consumo (Epagri 2020).

A Umidade do Solo (US) representa a quantidade de água presente nos poros do solo em um determinado momento. É uma variável essencial para o balanço hídrico, influenciando processos como evapotranspiração, recarga de aquíferos e crescimento vegetal. Seu monitoramento é fundamental para estudos de secas e gestão de recursos hídricos (Famiglietti e Rodell 2008). A Velocidade do Vento (VV) é a medida da movimentação do ar em determinada direção e intensidade. Essa variável influencia a taxa de evaporação e evapotranspiração, afetando o balanço hídrico e a demanda atmosférica por umidade. Seu monitoramento é essencial para modelagem climática e estudos de secas (Allen et al. 1998).

A Evaporação é o processo físico no qual a água passa do estado

líquido para o estado gasoso, desempenhando um papel essencial no ciclo hidrológico. Esse fenômeno ocorre em diversas superfícies naturais, como oceanos, lagos, rios, solo úmido e vegetação, incluindo a evaporação do orvalho e da água interceptada pelas folhas após precipitações. A medição direta da Evaporação é complexa e dispendiosa, tornando a obtenção de dados contínuos e representativos um desafio. Como alternativa, diversos métodos baseados em princípios físicos e equações empíricas são empregados para estimar a Evaporação, utilizando variáveis meteorológicas de fácil medição, como temperatura, umidade do ar, radiação solar e velocidade do vento. Essas estimativas são fundamentais para estudos hidrológicos, gestão de recursos hídricos e modelagem climática (Shuttleworth 2006; Thornthwaite 1948).

A Evapotranspiração Potencial (ETP) refere-se à taxa de evaporação de superfícies livres de água, como lagos e reservatórios. Esse processo depende da energia disponível para a evaporação e da capacidade da baixa atmosfera de transportar a umidade evaporada para longe da superfície terrestre. É um parâmetro fundamental para a hidrologia e o planejamento de recursos hídricos, influenciado por fatores como temperatura, umidade relativa, velocidade do vento e radiação solar.

A Evapotranspiração de Referência (ETR) representa a taxa de evapotranspiração de uma cultura de referência hipotética, caracterizada por uma altura uniforme de 0,12m, resistência da superfície de 70 sm^{-1} e um albedo de 0,23. Essa cultura cobre completamente a superfície e não sofre restrições hídricas, servindo como um padrão para a estimativa da demanda atmosférica de evapotranspiração em diferentes condições climáticas. A Evapotranspiração Real (ETR) representa a taxa efetiva de evapotranspiração observada em uma determinada área, considerando as condições ambientais e a disponibilidade de água no solo. Diferente da evapotranspiração potencial, a evapotranspiração real é limitada pela umidade do solo, sendo sempre menor ou igual à evapotranspiração potencial ($ETR \leq ETP$) (Shuttleworth 2006; Thornthwaite 1948).

3 Índices de Seca para cada tipo Seca

Os tipos da secas dependem de sua duração e são classificadas como: [Seca Meteorológica](#), [Seca Agrícola](#) e [Seca Hidrológica](#). A Figura 3 apresenta a distribuição percentual dos índices mais utilizados em estudos recentes sobre previsão de secas utilizando [AM](#) (Oyarzabal e L. Santos 2025). Esses índices desempenham um papel fundamental na caracterização da severidade e da frequência das secas, auxiliando na calibração e validação de modelos preditivos. A análise da sua aplicação permite identificar quais métricas têm sido mais eficazes na detecção e monitoramento de secas em diferentes contextos climáticos e hidrológicos (Bhuiyan 2004).




Figura 3: Mapa de árvore ilustrando os índices mais comumente usados em pesquisas para previsão de seca usando ML. A área de cada retângulo representa a proporção de uso para cada índice.

3.1 Aplicação

3.1.1 Seca Meteorológica

A [Seca Meteorológica](#) é definida pela falta de precipitação comumente quantificada usando o [Standardized Precipitation Index \(SPI\)](#) (Cunha et al. 2019)) e não necessariamente impacta a vegetação, a umidade do solo ou o suprimento de água. Ela depende da variabilidade climática natural bem como de mudanças climáticas antropogênicas. Como variabilidade climática natural, ocorre deficiência de precipitação em quantidade, intensidade e duração. Como consequência tem-se infiltração e escoamento reduzidos, percolação profunda e recarga de águas subterrâneas (Disaster Risk Reduction (UNDRR) 2021; Ashok K Mishra e Singh 2010b; Chang e Kleopa 1991; M. A. Santos 1983; ELTAHIR 1992; Svoboda e Fuchs 2016). No que concerne à mudança climática antropogênica, variáveis como alta temperatura, ventos fortes, baixa umidade relativa, mais luz do sol e menos cobertura de chuva (Disaster Risk Reduction (UNDRR) 2021; Ashok K Mishra e Singh 2010b; Chang e Kleopa 1991; M. A. Santos 1983; ELTAHIR 1992). A [Seca Meteorológica](#) é frequentemente avaliada por índices baseados em variáveis climáticas, como [Precipitação \(P\)](#), [Temperatura \(T\)](#) e [Evapotranspiração](#).

O [Aridity Anomaly Index \(AAI\)](#), que considera o balanço hídrico em tempo real. Este índice é calculado para períodos curtos, como semanas ou quinzenas, comparando a aridez real do período com a aridez normal correspondente. Valores negativos do [AAI](#) indicam excedentes de umidade, enquanto valores positivos sinalizam condições de estresse por déficit hídrico. Os parâmetros de entrada incluem evapotranspiração real e potencial, os quais dependem de variáveis como temperatura, vento e radiação solar, tornando-o relevante para estudos de previsão baseados em IA (World AgroMeteorological Information Service 2024).

O [Aridity Index \(AI\)](#) pode ser usado para classificar os climas de várias regiões. A relação entre precipitação e temperatura fornece um método para determinar o regime climático de uma área. O cálculo mensal deste índice pode ser usado para determinar o início da seca,

uma vez que ele leva em conta os impactos da temperatura, bem como a precipitação. Os parâmetros de entrada são a temperatura média mensal e precipitação. Para a classificação climática são utilizados os valores anuais. O **AI** é amplamente aplicado na classificação climática e monitoramento de secas (Baltas 2007).

O **Agricultural Reference Index for Drought (ARID)** prevê o estado de disponibilidade de umidade no solo. Ele usa uma combinação de aproximações de estresse hídrico e modelos de culturas para identificar o impacto do estresse hídrico nas plantas, crescimento, desenvolvimento e rendimento para culturas específicas. Os parâmetros de entrada são os dados diários de temperatura e precipitação. O modelo CERES-Maize também é utilizado, bem como outros modelos de simulação de culturas (Woli et al. 2012).

O **Crop Moisture Index (CMI)** é um índice de seca especialmente adequado aos impactos da seca na agricultura, na medida em que responde rapidamente a condições em rápida mudança. É calculado subtraindo a diferença entre a evapotranspiração potencial e umidade, para determinar qualquer déficit. Os parâmetros de entrada são a precipitação semanal, a temperatura média semanal e o valor **CMI** da semana anterior (W. C. Palmer 1968).

O **Drought Area Index (DAI)** compara a precipitação mensal durante o período crítico das monções na Índia. As intensidades dos períodos chuvoso e seco são obtidos e a importância da seca pode ser derivada com base na contribuição da precipitação de cada mês para a estação total das monções. Os parâmetros de entrada são os dados da precipitação mensal durante a estação das monções (Bhalme e Mooley 1980).

O **Drought Reconnaissance Index (DRI)** consiste em um índice de seca que contém uma equação simplificada do balanço hídrico, considerando a precipitação e a evapotranspiração potencial. Possui três saídas: o valor inicial, o valor normalizado e o valor padronizado. Os parâmetros de entrada são os valores mensais de temperatura e precipitação (Tsakiris e Vangelis 2005).

O **Effective Drought Index (EDI)** usa dados diários de precipitação para desenvolver e calcular vários parâmetros: precipitação efetiva (PE), média diária de PE, desvio de PE e o seu valor padronizado. Esses parâmetros podem identificar o início e o fim dos períodos de déficit hídrico. Usando os parâmetros de entrada, os cálculos de EDI podem ser realizados para qualquer local do mundo em que os resultados sejam padronizados para comparação, dando uma definição clara do início, fim e duração do seca. Os parâmetros de entrada são a precipitação diária (Byun e D. Wilhite 1999).

O **NOAA Drought Index (NDI)** é um índice baseado na precipitação em que a precipitação real medida é comparada com os valores normais durante a estação de crescimento. A precipitação média para cada semana é calculada e uma média contínua de oito semanas de precipitação média medida é somada e comparado. Se a precipitação real for superior a 60% da precipitação normal para o período de oito semanas, presume-se que a semana atual tenha pouco ou nenhum estresse hídrico. Se o estresse for detectado, ele permanecerá até que a precipitação real esteja em 60% ou mais do normal. O parâmetro de entrada é a precipitação mensal convertida em valores de precipitação semanais (Strommen e Motha 1987).

O **Palmer Drought Severity Index (PDSI)** usa dados mensais de temperatura e precipitação junto com informações sobre a capacidade de retenção de água dos solos. Leva em consideração a umidade recebida (precipitação), bem como a umidade armazenada no solo, contabilizando a potencial perda de umidade devido a influências de temperatura. Os parâmetros de entrada são os dados mensais de temperatura e precipitação. Podem ser utilizadas informações sobre a capacidade de retenção de água dos solos, mas também estão disponíveis padrões. É necessário um registro completo em série de temperatura e precipitação (Alley 1984).

Para o **Percent of Normal Precipitation (PNP)** um cálculo simples que pode ser usado para comparar qualquer período de tempo para qualquer local. Pode ser calculado em escalas de tempo diárias, sema-

nais, mensais, sazonais e anuais, o que atenderá a muitas necessidades do usuário. Calculado dividindo a precipitação real pela precipitação normal para o tempo sendo considerado e multiplicado por 100. Os parâmetros de entrada são os valores de precipitação adequados para a escala de tempo que está sendo calculada. É ideal ter dados de pelo menos 30 anos para o cálculo do período normal (Hayes 2006).

O [Standardized Anomaly Index \(SAI\)](#) foi desenvolvido para ajudar a identificar secas em regiões suscetíveis, como o Sahel da África Ocidental e o Nordeste do Brasil. Este índice contabiliza precipitação baseada em estações em uma região e padroniza os valores anuais. Os desvios são então calculada a média de todas as estações da região para obter um único valor [SAI](#). Os parâmetros de entrada são a precipitação em intervalos de tempo mensais, sazonais ou anuais (Katz e Glantz 1986).

Sendo um índice de seca relativamente novo, o [Standardized Precipitation Evapotranspiration Index \(SPEI\)](#) utiliza a base do [Standardized Precipitation Index \(SPI\)](#), mas inclui um componente de temperatura, permitindo que o índice leve em conta o efeito da temperatura na seca desenvolvimento através de um cálculo básico do balanço hídrico. Possui uma escala de intensidade na qual são calculados valores positivos e negativos, identificando eventos úmidos e secos. Pode ser calculado para intervalos de tempo de 1 mês até 48 meses ou mais. Os parâmetros de entrada são os dados mensais de precipitação e temperatura. É necessário um registro completo de dados em série, sem meses faltantes (Vicente-Serrano, Beguería e López-Moreno 2010).

O [Standardized Precipitation Index \(SPI\)](#) usa registros históricos de precipitação para qualquer local para desenvolver uma probabilidade de precipitação que pode ser calculada em qualquer número de escalas de tempo, de 1 mês a 48 meses ou mais longo. Os parâmetros de entrada são os dados de precipitação. A maioria dos usuários aplica o [SPI](#) usando conjuntos de dados mensais, mas os programas de computador têm flexibilidade para produzir resultados ao usar valores diários e semanais. A metodologia do [SPI](#) não muda com base no uso de dados diários, semanais ou mensais (Guttman 1998).

O [Weighted Anomaly Standardized Precipitation Index \(WASP\)](#) usa dados de precipitação mensal em grade com resolução de $0,5^\circ \times 0,5^\circ$ e é baseado em somas sobrepostas de 12 meses de anomalias de precipitação mensais padronizadas e ponderadas. Os parâmetros de entrada são a precipitação mensal e valores de precipitação anual (Lyon 2004).

3.1.2 Seca Agrícola

Na [Seca Agrícola](#) a disponibilidade de umidade para as plantas cai a tal nível que afeta negativamente o rendimento das culturas e, portanto, a rentabilidade agrícola. Diz respeito à deficiência de umidade do solo em relação às secas meteorológicas e aos fatores climáticos e aos seus impactos na produção agrícola e na rentabilidade econômica (Disaster Risk Reduction (UNDRR) 2021; Mannocchi, Francesca e Vergni 2004). Este tipo de seca pode ser melhor estudado por meio de uma análise regional envolvendo um conjunto de variáveis associadas ao processo de consumo de água das culturas, mas as interações são muito complexas (Mannocchi, Francesca e Vergni 2004).

O [Evapotranspiration Deficit Index \(ETDI\)](#) é um produto semanal que é útil para identificar o estresse hídrico nas culturas. É calculado juntamente com o Índice de Déficit de Umidade do Solo (SMDI), no qual uma relação de estresse hídrico é calculado e compara a evapotranspiração real com a evapotranspiração da cultura de referência. A razão de stress hídrico é então comparada com a mediana calculada ao longo de um período de longo prazo. Os parâmetros de entrada são os dados de um modelo hidrológico com o modelo Soil and Water Assessment Tool (SWAT) que são usados inicialmente para calcular a água do solo na zona radicular semanalmente (Narasimhan e Srinivasan 2005).

O [Soil Moisture Anomaly \(SMA\)](#) pode usar valores semanais ou mensais de precipitação e evapotranspiração potencial em uma equação simples de balanço hídrico. Pretende-se refletir o grau de secura ou saturação do solo em comparação com condições normais e mostrar

como o stress hídrico do solo influencia a produção agrícola em todo o mundo. Os parâmetros de entrada são os dados semanais ou mensais de temperatura e precipitação, juntamente com data e latitude. Podem ser utilizados valores para a capacidade de retenção de umidade do solo e dados específicos do local, embora sejam incluídos valores predefinidos (Bergman, Sabol e Miskus 1988).

O [Soil Moisture Deficit Index \(SMDI\)](#) é um produto semanal de umidade do solo calculado em quatro profundidades diferentes, incluindo a coluna total do solo, em 0,61, 1,23 e 1,83m, e pode ser utilizado como indicador de seca de curta duração, especialmente utilizando os resultados da camada de 0,61m. Os parâmetros de entrada são os dados modelados de um modelo hidrológico com o modelo SWAT são usados inicialmente para calcular a água do solo na zona radicular semanalmente (Narasimhan e Srinivasan 2005).

O [Soil Water Storage \(SWS\)](#) identifica a quantidade de umidade disponível na zona radicular de uma planta, que depende do tipo de planta e do tipo de solo. A precipitação e a irrigação afetam a resultados. Os parâmetros de entrada são a profundidade de enraizamento, capacidade de armazenamento de água disponível no tipo de solo e déficit máximo de água no solo (British Columbia Ministry of Agriculture 2015).

3.1.3 Seca Hidrológica

A [Seca Hidrológica](#) refere-se à falta de água no sistema hidrológico, manifestando-se em vazões anormalmente baixas nos rios e níveis anormalmente baixos em lagos, reservatórios e águas subterrâneas. Faz parte do fenômeno maior da seca que denota um perigo natural recorrente. Pode cobrir áreas extensas e durar meses ou anos, com impactos devastadores no sistema ecológico e em muitos setores econômicos (Disaster Risk Reduction (UNDRR) 2021; Van Loon 2015).

O [Palmer Hydrological Drought Severity Index \(PHDI\)](#) é baseado no [PDSI](#) original e modificado para ter em conta a seca a longo prazo que afetará o armazenamento de água, o fluxo dos rios e as águas

subterrâneas. O [PHDI](#) tem a capacidade de calcular quando uma seca terminará com base na precipitação necessária, usando uma proporção entre a umidade recebida e a umidade necessária para acabar com uma seca. Existem quatro categorias de seca: quase normal, o que ocorre aproximadamente 28%–50% das vezes; leve a moderado, que ocorre aproximadamente 11%–27% das vezes; grave, que ocorre aproximadamente 5% a 10% das vezes; e extremo, que ocorre aproximadamente 4% das vezes. Os parâmetros de entrada são a temperatura e precipitação mensais. Informações sobre a capacidade de retenção de água dos solos podem ser utilizadas, mas os padrões devem também ser disponíveis. É necessário um registro completo em série dos dados de temperatura e precipitação (Wayne C Palmer 1965).

O [Streamflow Drought Index \(SDI\)](#) usa valores mensais de vazão e os métodos de normalização associados com o [SPI](#) para desenvolver um índice de seca baseado em dados de vazão. Com uma saída semelhante a do [SPI](#), tanto os períodos úmidos quanto os secos podem ser investigados, bem como a severidade destas ocorrências. Os parâmetros de entrada são: valores mensais de vazão e uma série temporal histórica para o medidor de vazão (Nalbantis e Tsakiris 2008).

O [Standardized Reservoir Supply Index \(SRSI\)](#) é semelhante ao [SPI](#), pois os dados mensais são usados para calcular uma função de distribuição de probabilidade de dados de armazenamento de reservatórios, para fornecer informações sobre o abastecimento de água para um região ou bacia dentro de uma faixa de -3 (extremamente seca) a +3 (extremamente úmida). Os parâmetros de entrada são as afluências mensais dos reservatórios e volumes médios de armazenamento dos reservatórios (Gusyev et al. 2015).

O [Standardized Streamflow Index \(SSFI\)](#) foi desenvolvido usando valores mensais de vazão e os métodos de normalização associada ao [SPI](#). Pode ser calculado para dados observados e previstos, proporcionando uma perspectiva sobre períodos de caudal alto e baixo associados a secas e cheias. Os parâmetros de entrada são dados de vazão em uma escala de tempo diária ou mensal (Modarres 2007).

O [Standardized Water-level Index \(SWI\)](#) é utilizado como um indicador de seca baseado na hidrologia, utiliza dados de poços para investigar o impacto da seca na recarga das águas subterrâneas. Os resultados podem ser interpolados entre pontos. Os parâmetros de entrada são níveis de poço de água subterrânea (Bhuiyan [2004](#)).

O [Surface Water Supply Index \(SWSI\)](#) leva em consideração o trabalho realizado por Palmer com [PDSI](#), mas acrescenta informações, incluindo dados de abastecimento de água (acúmulo de neve, degelo e escoamento, e dados do reservatório), e é calculado ao nível da bacia. [SWSI](#) identifica a frequência aproximada de ocorrência de seca leve em 26% – 50%, ocorrência de seca moderada em 14%–26% e seca severa ocorrência de seca em 2% - 14%. A seca extrema ocorre aproximadamente menos de 2% do tempo. Os parâmetros de entrada são o armazenamento de reservatórios, fluxo, neve acumulada e precipitação (Doesken e Garen [1991](#)).

3.2 Dados de Sensoriamento Remoto

O [Enhanced Vegetation Index \(EVI\)](#) faz o monitoramento de vegetação a partir de plataformas de satélite usando o Advanced Very High Radiômetro de Resolução (AVHRR) para calcular o Índice de Vegetação por Diferença Normalizada [NDVI](#) é bastante útil. O [EVI](#) usa algumas das mesmas técnicas do [NDVI](#), mas com os dados de entrada de um Satélite baseado em MODIS. Tanto o [EVI](#) quanto o [NDVI](#) são calculados usando a plataforma MODIS e analisados sobre seu desempenho em comparação com as plataformas AVHRR. O [EVI](#) é mais responsivo às variações da copa, ao tipo e arquitetura da copa e à fisionomia da planta. O [EVI](#) pode estar associado a estresse e mudanças relacionadas à seca. Os parâmetros de entrada são as informações de satélite baseadas em MODIS (Huete et al. [2002](#)).

O [Evaporative Stress Index \(ESI\)](#) foi estabelecido como um novo índice de seca no qual a evapotranspiração é comparada à evapotranspiração potencial usando satélites geostacionários. As análises sugerem

que o seu desempenho é semelhante ao dos índices baseados na precipitação de curto prazo, mas pode ser produzido com uma resolução muito maior e sem a necessidade de dados de precipitação. Os parâmetros de entrada são a evapotranspiração potencial detectada remotamente (Anderson et al. [2011](#)).

O [Normalized Difference Vegetation Index \(NDVI\)](#) utiliza os dados do índice global de vegetação, que são produzidos através do mapeamento de 4 km de brilho diário. Valores de radiância medidos nos canais visível e infravermelho próximo são usados para calcular o [NDVI](#). Mede o verde e o vigor da vegetação durante um período de sete dias como um forma de reduzir a contaminação das nuvens e pode identificar o estresse causado pela seca na vegetação. Os parâmetros de entrada são os dados do satélite NOAA AVHRR (Kogan [1995](#)).

Usando bandas térmicas AVHRR, o [Temperature Condition Index \(TCI\)](#) é usado para determinar o estresse na vegetação causada por temperaturas e umidade excessiva. As condições são estimadas em relação à temperaturas máximas e mínimas e modificadas para refletir as diferentes respostas da vegetação à temperatura. Os parâmetros de entrada são os dados do satélite AVHRR (Kogan [1995](#)).

Usando bandas térmicas AVHRR, o [Vegetation Condition Index \(VCI\)](#) é usado para identificar situações de seca e determinar o início, especialmente em áreas onde os episódios de seca são localizados e mal definidos. Isto concentra-se no impacto da seca na vegetação e pode fornecer informações sobre o início, duração e severidade da seca, observando as mudanças na vegetação e comparando-as com valores históricos. Os parâmetros de entrada são os dados do satélite AVHRR (Kogan [1995](#)).

O [Vegetation Drought Response Index \(VegDRI\)](#) foi desenvolvido como um índice de seca que pretendia monitorar estresse da vegetação usando uma combinação de sensoriamento remoto, indicadores baseados no clima e outras informações biofísicas e dados de uso da terra. Os são: [SPI](#), [PDSI](#), , percentagem de vegetação sazonal anual, anomalia de início de época, cobertura do solo, capacidade de água disponível no

solo, agricultura irrigada e regiões ecológicas definidas. Como algumas das entradas são variáveis derivadas, são necessárias entradas adicionais (Brown et al. 2008).

O [Vegetation Health Index \(VHI\)](#) foi uma das primeiras tentativas de monitorizar e identificar os impactos agrícolas relacionados com a seca utilizando dados de detecção remota. Os dados AVHRR nos canais visível, infravermelho e infravermelho próximo são usados para identificar e classificar o estresse na vegetação devido à seca. Os parâmetros de entrada são os dados do satélite AVHRR (Kogan 2001).

O [Water Requirement Satisfaction Index \(WRSI\)](#) é usado para monitorar o desempenho da cultura durante a estação de crescimento e com base na quantidade de água disponível para a cultura. É uma relação entre a evapotranspiração real e a potencial. Estes rácios são específicos da cultura e baseiam-se no desenvolvimento da cultura e nas relações conhecidas entre rendimentos e stress hídrico. Os parâmetros de entrada são os modelos de desenvolvimento de culturas, coeficientes de culturas e dados de satélite (Verdin e Klaver 2002).

Finalmente, [Normalized Difference Water Index \(NDWI\)](#) e [Land Surface Water Index \(LSWI\)](#), muitos semelhantes à metodologia [NDVI](#), mas utilizam o canal do infravermelho próximo para monitorar o conteúdo de água da copa da vegetação. Mudanças na copa da vegetação são aproveitadas para identificar períodos de estresse hídrico. Os parâmetros de entrada são as informações de satélite nos vários canais do espectro do infravermelho próximo (Kogan 2001).

3.3 Índices Compostos ou Modelados

O [Combined Drought Indicator \(CDI\)](#) é composto por três níveis de alerta (assistir, avisar e alertar) integrando três indicadores de seca: [SPI](#), umidade do solo e dados de vegetação de sensoriamento remoto. Uma vigilância é indicada quando há escassez de precipitação, um nível de alerta é atingido quando a escassez de precipitação se traduz numa escassez de humidade do solo, e um aviso ocorre quando os défices de

precipitação e de humidade do solo se traduzem num impacto sobre a vegetação. Os parâmetros de entrada são: [SPI](#) calculado a partir de dados de precipitação baseados em estações em toda a Europa; neste caso, utiliza-se o [SPI](#) de três meses. Os dados de umidade do solo são obtidos usando o modelo LISFLOOD, e o fAPAR vem da Agência Espacial Europeia (Sepulcre-Canto et al. 2012).

O [Global Integrated Drought Monitoring and Prediction System \(GIDMaPS\)](#) fornece informações sobre seca para [SPI](#), umidade do solo e Índice Multivariado de Seca Padronizado [MSDI](#). O GIDMaPS também utiliza dados de satélite combinados com ferramentas de assimilação de dados. O produto é produzido em grade quase em tempo real e combina monitoramento e previsão como forma de monitorar, avaliar e antecipar secas com múltiplos impactos. Como parâmetro de entrada uso-se um algoritmo no qual dados de sensoriamento remoto são combinados com o índice do Sistema Global de Assimilação de Dados Terrestres [GLDAS](#) para produzir resultados para três índices de seca, bem como previsões sazonais (Hao, AghaKouchak et al. 2014).

O [Global Land Data Assimilation System \(GLDAS\)](#) utiliza um sistema de dados de superfície e de sensoriamento remoto, juntamente com modelos de superfície terrestre e técnicas de assimilação de dados para fornecer dados sobre as condições terrestres. Os resultados incluem as características da humidade do solo, que são um bom indicador de seca. Os parâmetros de entrada são: modelos de superfície terrestre, observações meteorológicas baseadas na superfície, classificações de vegetação e dados de satélite (Mitchell et al. 2004).

O [Multivariate Standardized Drought Index \(MSDI\)](#) utiliza informações sobre precipitação e umidade do solo para identificar e classificar episódios de seca, investigando a precipitação e os déficits de umidade do solo. É útil para identificar episódios de seca onde os indicadores típicos baseados na precipitação ou na humidade do solo os indicadores podem não indicar a presença de seca. Os parâmetros de entrada são os dados mensais de precipitação e umidade do solo são necessários a partir dos sistemas Modern Era Retrospective Analysis

(MERRA)-Land. Os dados MERRA-Land são gerados por um ângulo de $0,66^\circ \times$ Grade de $0,50^\circ$ a partir de 1980 (Hao e AghaKouchak 2013).

O **USDM (United States Drought Monitor)** utiliza um método de classificação percentual no qual índices e indicadores de vários períodos de registro podem ser comparados de forma equivalente. Tem uma escala de cinco níveis de intensidade, desde condições anormalmente secas que ocorrerão a cada três a cinco anos, até secas excepcionais. condições que ocorrerão aproximadamente uma vez a cada cinquenta anos. É flexível porque qualquer número de entradas pode ser usado e possui um arquivo Como é flexível, não há número definido de parâmetros de entrada. Originalmente, apenas alguns insumos eram usados; atualmente, a construção do **USDM** envolve a análise de 40 a 50 insumos. Índices de seca, umidade do solo, dados hidrológicos, dados climatológicos, dados modelados e dados de sensoriamento remoto estão todos incluídos na análise. À medida que novos indicadores são desenvolvidos, o **USDM** é suficientemente flexível para incluí-los também (Svoboda, Lecomte et al. 2002).

O **Índice Integrado de Seca (IIS)** consiste na combinação do **SPI**, a Água Disponível no Solo (ADS) juntamente com o Índice de Suprimento de Água para a Vegetação (VSWI) ou com o **SPI**, ambos estimados por sensoriamento remoto.

O índice negativo representa condições de déficit hídrico, nas quais a precipitação é inferior à média climatológica. O índice positivo representa condições de excesso hídrico, que indicam precipitação superior à média histórica.

Para integrar o **IIS**, o **SPI** é calculado a partir de dados observacionais de precipitação disponíveis no CEMADEN, no Instituto Nacional de Meteorologia (INMET), no Instituto Nacional de Pesquisas Espaciais (INPE) e nos Centros Estaduais de Meteorologia.

O **SPI** é calculado considerando as escalas de 3, 6 e 12 meses, obtendo como produto final **SPI** na resolução espacial $5km$. O **IIS** possui as seguintes classes: condição normal (6), seca fraca (5), seca moderada (4), seca severa (3), seca extrema (2) e seca excepcional (1).

4 Métodos de aprendizado de máquina usados para previsão de seca

O uso de métodos de aprendizado de máquina na previsão de secas tem se consolidado devido à sua capacidade de lidar com incertezas e prever em diferentes escalas temporais, proporcionando maior confiabilidade e eficiência aos modelos utilizados nesta área. Esses métodos podem ser classificados em sete categorias principais com base em seus processos de aprendizagem: redes neurais artificiais **Artificial Neural Networks (ANN)**, árvores de decisão **Decision Trees (DT)**, sistemas neuro-fuzzy adaptativos **Adaptive Neuro-Fuzzy Inference System (ANFIS)** (Jang 1993), modelos de médias móveis integradas auto-regressivas **Auto-Regressive Integrated Moving Average (ARIMA)**, métodos de ensemble **Ensemble**, máquinas de vetor de suporte **Support Vector Machines (SVM)** (Cortes 1995), entre outros. Cada classe apresenta vantagens específicas para diferentes tipos de dados e aplicações. A Figura 4 mostra os métodos de **AM** mais utilizados nos estudo de previsão de seca nos últimos anos (Oyarzabal e L. Santos 2025).

4.1 Classe ANN

A classe **ANN** engloba todos os modelos de redes neurais considerados para estudos de secas, abrangendo diversas arquiteturas e metodologias avançadas. Cada uma dessas abordagens apresenta características únicas que as tornam úteis para diferentes aspectos da modelagem de secas, como previsão, classificação e análise temporal.

O **Multilayer Perceptron (MLP)** é um tipo de rede neural artificial composta por múltiplas camadas de neurônios, capaz de modelar relações complexas entre dados (Hornik, Stinchcombe e White 1989). A **Convolutional Neural Network (CNN)** é uma arquitetura especializada no processamento de dados estruturados em grades, como imagens, utilizando camadas convolucionais para capturar padrões espaciais (Fukushima 1980). Já a **Bayesian Convolutional Neural Network (BCNN)**

é uma variação da CNN que incorpora incertezas probabilísticas nos seus pesos, tornando-a útil para aplicações onde a quantificação da incerteza é essencial. O [Deep Learning \(DL\)](#) refere-se a um conjunto de técnicas que utilizam redes neurais profundas para aprendizado de alto nível, sendo amplamente aplicado em reconhecimento de padrões e modelagem de séries temporais (Goodfellow, Bengio e Courville 2016; LeCun, Bengio e G. Hinton 2015).




Figura 4: Métodos de aprendizado de máquina mais comumente usados para previsão de seca.

A [Deep Belief Network \(DBN\)](#) é uma arquitetura de aprendizado profundo composta por múltiplas camadas de redes neurais probabilísticas, eficiente para extração de características e aprendizado não supervisionado (G. E. Hinton, Osindero e Teh 2006). A [Discrete Wa-](#)

[velet Transform Neural Network \(DWT-ANN\)](#) combina redes neurais artificiais com a Transformada Wavelet Discreta, permitindo a análise de sinais em diferentes escalas e melhorando a modelagem de séries temporais (Murtagh e Starck 1995). O [Genetic Algorithm-Multilayer Perceptron \(GA-MLP\)](#) integra Algoritmos Genéticos com Perceptron Multicamadas para otimizar pesos e estrutura da rede, aprimorando a capacidade de generalização (Yao 1999).

A [General Regression Neural Network \(GRNN\)](#) é um tipo de rede neural baseada em regressão estatística, útil para aproximação de funções e previsão (Specht 1991). Já a [Gate Recurrent Unit \(GRU\)](#) é uma variante das redes recorrentes que utiliza unidades de portão para capturar dependências temporais em séries temporais, reduzindo o problema do desaparecimento do gradiente (Cho et al. 2014).

A [Long-Short Term Memory Network \(LSTM\)](#) é um tipo de rede neural recorrente projetada para capturar dependências de longo prazo em séries temporais, evitando o problema do desaparecimento do gradiente (Hochreiter e Schmidhuber 1997). O [Multilayer Perceptron with Extended Kalman Filter \(MLP-EKF\)](#) combina o Perceptron Multicamadas com o Filtro de Kalman Estendido, permitindo atualizações dinâmicas dos pesos da rede para melhorar previsões em sistemas não lineares (Haykin 2001). A [Radial Basis Function Neural Network \(RBFNN\)](#) utiliza funções de base radial como unidades de ativação, sendo eficaz para aproximação de funções e classificação de padrões (Broomhead e Lowe 1988).

A [Recurrent Neural Network \(RNN\)](#) é um modelo de rede neural que processa dados sequenciais considerando dependências temporais, sendo amplamente aplicada em modelagem de séries temporais (Rumelhart, G. E. Hinton e Williams 1986). Por fim, a [Wavelet Artificial Neural Networks \(WANN\)](#) integra redes neurais artificiais com transformadas wavelet, aprimorando a análise de sinais e a extração de características multiescalares (Qinghua Zhang e Benveniste 1992).

4.2 Classe DT

A classe **DT** abrange os algoritmos baseados em árvores de decisão, amplamente utilizados na previsão de secas devido à sua simplicidade, interpretabilidade e eficácia na modelagem de dados (Quinlan 1986).

Entre os principais métodos dessa classe estão: o **M5Pruned (M5P)**, que utiliza a poda para melhorar a generalização do modelo (Quinlan 1992); o **M5Tree (M5T)**, uma variação que implementa estratégias específicas para dividir os dados; o **Reduced Error Pruning Tree (REPT)**, que emprega a poda por erro reduzido para evitar o superajuste (Y. Wang e Witten 1997); e a própria **DT**, uma abordagem clássica e versátil para classificação e regressão (Esposito, Malerba e Semeraro 1997).

Esses algoritmos são conhecidos por sua capacidade de capturar relações complexas entre variáveis e são frequentemente utilizados como base para métodos mais avançados, como florestas aleatórias e ensembles.

4.3 Classe Ensemble

A classe **Ensemble** (Dietterich 2000) reúne algoritmos baseados em aprendizado por conjuntos, amplamente reconhecidos por combinar múltiplos modelos para aumentar a precisão e a robustez na previsão de secas.

Entre os principais métodos estão: o **Adaptive Boosting (Adaboost)**, que ajusta pesos em cada iteração para melhorar o desempenho (Freund e Schapire 1997); o **Bootstrap Aggregating Trees (BAT)**, que utiliza árvores de decisão agregadas por bootstrap para reduzir a variância do modelo (X.-S. Yang 2010); o **Bootstrap Aggregating Trees-Algorithm Optimised Extreme Learning Machine (BAT-ELM)**, que integra o **BAT** com o Algoritmo Otimizado de Máquinas de Aprendizado Extremo (Gao, Xuebo Zhang e Liang 2015); o **Bootstrap Aggregating (BG)**, uma abordagem geral de agregação bootstrap (Breiman 1996).

Temos ainda o **Boosted Trees (BT)**, que combina árvores de decisão por boosting (Friedman 2001); o **Extremely Randomized Trees ET**,

conhecido por gerar árvores extremamente randomizadas (Pierre Geurts e Wehenkel 2006); o **Gradient Boosting Machine (GBM)**, que constrói modelos robustos através do gradiente de boosting (Friedman 2002).

O **Gene-Random Forest (GeRF)**, que incorpora técnicas genéticas em florestas aleatórias (Biau e Scornet 2016); o **Light Gradient Boosting Machine (LGBM)**, reconhecido por sua eficiência em grandes conjuntos de dados (Ke et al. 2017).

O **Random Forest (RF)**, uma das abordagens mais populares para aprendizado em conjuntos (Breiman 2001); o **Random Subspace (RS)**, que utiliza subconjuntos aleatórios de atributos (Ho 1998); o **Random Tree (RT)**, que gera árvores aleatórias para robustez e simplicidade (Amit e Geman 1997).

O **Wavelet Boosting (WB)**, que aplica técnicas de wavelet para melhorar o boosting (Freund e Schapire 1997); e o **Extreme Gradient Boosting (XGBoost)**, um dos métodos mais avançados em aprendizado por gradiente (T. Chen e Guestrin 2016).

Esses algoritmos são fundamentais em aplicações de previsão devido à sua flexibilidade e capacidade de capturar padrões complexos.

4.4 Classe ANFIS

A classe **Adaptive Neuro-Fuzzy Inference System (ANFIS)** refere-se a modelos baseados em lógica fuzzy, amplamente utilizados na previsão de secas devido à sua capacidade de lidar com incertezas e integrar informações qualitativas e quantitativas. Entre os principais modelos dessa categoria está o próprio **Adaptive Neuro-Fuzzy Inference System (ANFIS)**, que combina redes neurais artificiais com lógica fuzzy para criar um sistema adaptativo eficiente (Jang 1993).

Outros modelos incluem o **Fuzzy Rule-Based System (FRBS)**, que utiliza regras fuzzy para representar relações complexas (Zadeh 1973); o **Weighted Wavelet Fuzzy (WWF)**, que incorpora wavelets ponderadas para capturar variações temporais e espaciais (Wiener 1949); e o **Wavelet Fuzzy (WF)**, que aplica transformadas wavelet para melhorar a análise

de dados (Kailath 1974).

Esses métodos são fundamentais para compreender os padrões de seca e suas dinâmicas complexas.

4.5 Classe ARIMA

A classe [Autoregressive Integrated Moving Average \(ARIMA\)](#) refere-se a modelos de previsão de séries temporais, amplamente aplicados em estudos de seca para identificar padrões e prever condições futuras. O modelo Autoregressivo Integrado de Médias Móveis [Auto-Regressive Integrated Moving Average \(ARIMA\)](#) é o mais conhecido dessa categoria, utilizando componentes autoregressivos e médias móveis para capturar dependências temporais nos dados (Box e Jenkins 1970).

Outras variações incluem o [ARIMA-LSTM](#), que combina o ARIMA com redes neurais de memória de curto e longo prazo [Long-Short Term Memory Network \(LSTM\)](#) para aprimorar a capacidade de modelar padrões complexos (G. Zhang 2003). O [ARIMA-SVR](#) integra o ARIMA com regressão por vetor de suporte [Support Vector Regressor \(SVR\)](#), criando um modelo híbrido que melhora a precisão da previsão (Pai e Lin 2005).

Por fim, o modelo [Autoregressive Integrated Moving Average with Exogenous Variables \(ARIMAX\)](#) incorpora variáveis exógenas ao ARIMA, permitindo a inclusão de fatores externos que influenciam diretamente as condições de seca (Peña, Tiao e Tsay 2011).

4.6 Classe SVM

A classe [Support Vector Machine \(SVM\)](#) refere-se a um algoritmo de aprendizado supervisionado amplamente utilizado em tarefas de classificação e regressão, com aplicações notáveis no estudo de secas. O modelo principal, [Support Vector Machines \(SVM\)](#), é baseado no conceito de encontrar um hiperplano ótimo para separar classes ou prever valores em um espaço multidimensional (Cortes 1995).

Entre suas variações, destacam-se o [Support Vector Regressor \(SVR\)](#), voltado para tarefas de regressão (Drucker et al. 1997), e o [Least-Square Support Vector Machine \(LSSVM\)](#), que reduz a complexidade computacional ao minimizar os erros quadrados (Suykens, Gestel et al. 2002). Outras extensões incluem o [Least-Square SVR \(LS-SVR\)](#), uma abordagem específica para regressão (Suykens e Vandewalle 1999), e o [Support Vector Machine Regression \(SVMR\)](#), que aplica técnicas de regressão diretamente no SVM (Vapnik, Golowich e Smola 1996).

Modelos híbridos, como o [Support Vector Machine-Grey Wolf Optimizer \(SVR-GWO\)](#), que integra o SVM com o Otimizador do Lobo Cinzento (Seyedali Mirjalili 2014), e o [Support Vector Machine-Spotted Hyena Optimizer \(SVR-SHO\)](#), que utiliza o Otimizador da Hiena Pintada, oferecem maior precisão em cenários complexos (Ahmadreza Gandomi 2020). Por fim, o [Wavelet Least-Square SVR \(WLS-SVR\)](#) combina o SVM com transformadas wavelet, fornecendo uma abordagem poderosa para análise de séries temporais (L. Wang et al. 2005).

4.7 Outras classes

Por fim, a classe [Outras Classes](#) inclui uma ampla variedade de modelos utilizados para estudos de secas, demonstrando a diversidade e a flexibilidade dos métodos de previsão disponíveis.

Entre os modelos destacados, estão os baseados em análise de flutuação, como o [Detrended Fluctuation Analysis \(DFA\)](#) (Peng et al. 1994), e os que utilizam aprendizado extremo, como o [Extreme Learning Machine \(ELM\)](#), incluindo suas variações híbridas [Estimation of Distribution Algorithm-Extreme Learning Machine \(EDA-ELM\)](#), [Wavelet Extreme Learning Machine \(WELM\)](#) e [Genetic Algorithm-Extreme Learning Machine \(GA-ELM\)](#) (Huang, Zhu e Siew 2006; Z.-H. Yang, W. Zhang e Y.-X. Yang 2013; Zong, Huang e Y. Chen 2013; Wen, Zhou e Xu 2010).

Outras abordagens incluem técnicas baseadas em algoritmos genéticos, como [Genetic Expression Programming \(GEP\)](#), métodos

de agrupamento, como [K-means](#), e métodos estatísticos, como [Lasso Regression \(LR\)](#), [Multiple Linear Regression \(MLR\)](#) e [Ordinary Least Squares \(OLS\)](#) (Seber e Lee 2003; Montgomery, Peck e Vining 2012; MacQueen 1967; Ferreira 2001).

Métodos de aprendizado probabilístico, como o [Naive Bayes \(NB\)](#) (Webb, Keogh e Mikkilainen 2010), e modelos de processos gaussianos, como [Gaussian Process \(GP\)](#) e [Gaussian Process Regression \(GPR\)](#), também estão presentes (MacKay et al. 1998).

Adicionalmente, modelos de redes não lineares, como [Nonlinear Auto-Regressive \(NAR\)](#) e [Nonlinear Auto-Regressive with Exogenous \(NARX\)](#), e variações de aprendizado sequencial, como [Online Sequential Extreme Learning Machine \(OSELM\)](#) e [Kalman filter regression-based Online Sequential Extreme Learning Machine \(KOSELM\)](#), completam esta classe abrangente, destacando a evolução e a integração de técnicas avançadas para previsão de secas (H. Zhang, S. Zhang e Yin 2018; J. Zhang, Feng e Yu 2017; Siegelmann, Horne e Giles 1997).

5 Conclusão

O número de artigos científicos relacionados à previsão de secas e aos métodos de Aprendizado de Máquina tem crescido nos últimos anos, evidenciando que este é um campo promissor para pesquisas futuras. Esse aumento impulsionou o desenvolvimento de novas abordagens para a análise de padrões de seca no espaço e no tempo, além de estratégias inovadoras para a previsão desses eventos. O uso do [AM](#) possibilita a identificação de padrões inéditos de seca, especialmente em um cenário de mudanças climáticas, que têm alterado os regimes conhecidos de

eventos extremos ao redor do mundo.

Entretanto, a ampla variedade de metodologias e bases de dados disponíveis pode gerar incertezas quanto à melhor alternativa para detectar e modelar padrões de seca. A seca meteorológica tem sido o tipo mais estudado nesse contexto, devido à facilidade de estimativa baseada apenas em dados de precipitação. Em contrapartida, as secas agrícola e hidrológica ainda são menos exploradas em modelos de Aprendizado de Máquina, pois demandam dados adicionais com alta resolução espaço-temporal, como umidade do solo, cobertura e uso da terra, vazão de rios e dados de águas subterrâneas.

A escassez de bancos de dados históricos de umidade do solo de longo prazo representa um desafio significativo, dado o alto grau de complexidade envolvido em suas medições. Nos últimos anos, entretanto, avanços tecnológicos, como novos satélites e sensores remotos, têm viabilizado a medição da umidade do solo em grandes áreas, fornecendo subsídios valiosos para pesquisas futuras sobre seca agrícola.

Manter uma rede de monitoramento abrangente, que contemple todas essas variáveis, continua sendo um grande desafio, sobretudo em países de grande extensão territorial e diversidade climática, como o Brasil e o continente africano.

Nesse contexto, este glossário representa um esforço abrangente na sistematização de indicadores e índices de seca, além de conceitos essenciais para a previsão e o monitoramento desses eventos, com ênfase no uso do Aprendizado de Máquina. Ao compilar e organizar esses termos, o trabalho contribui para a disseminação científica, facilitando o acesso e a compreensão de conceitos fundamentais sobre secas e inteligência artificial, além de promover a consolidação do conhecimento nessa área de estudo.

Glossário

Adaptive Boosting (Adaboost) Algoritmo de aprendizado em conjunto que ajusta os pesos das observações em cada iteração para melhorar o desempenho do modelo. [16](#)

Adaptive Neuro-Fuzzy Inference System (ANFIS) Modelo que combina redes neurais artificiais e lógica fuzzy para criar um sistema de inferência adaptativo, amplamente utilizado em previsão de secas. [16](#)

Adaptive Neuro-Fuzzy Inference System (ANFIS) Sistema neuro-fuzzy adaptativo que combina redes neurais e lógica fuzzy, permitindo modelar incertezas e relações complexas entre dados climáticos e secas. [14](#), [16](#)

Agricultural Reference Index for Drought (ARID) Índice de referência agrícola para seca, usado para avaliar o impacto da seca na agricultura com base em variáveis como precipitação, evapotranspiração e umidade do solo. [9](#)

Aprendizado de Máquina (AM) Subcampo da Inteligência Artificial que desenvolve algoritmos capazes de aprender padrões a partir de dados e realizar previsões ou tomadas de decisão. É amplamente utilizado para modelagem e previsão de secas, permitindo a análise de grandes volumes de dados ambientais e climáticos. [3–8](#), [14](#), [18](#)

Aridity Anomaly Index (AAI) Índice de anomalia de aridez que utiliza balanço hídrico em tempo real para avaliar estresse hídrico ou excedentes de umidade. [8](#)

Aridity Index (AI) Índice de aridez que mede a razão entre a precipitação anual e a evapotranspiração potencial anual (P/ETP). Utilizado para classificar climas em relação à disponibilidade hídrica. [8](#), [9](#)

ARIMA-LSTM Modelo híbrido que integra o ARIMA com redes neurais de memória de curto e longo prazo (LSTM) para capturar padrões complexos em séries temporais. [17](#)

ARIMA-SVR Modelo que combina o ARIMA com regressão por vetor de suporte (SVR), criando um sistema híbrido para aumentar a precisão da previsão. [17](#)

Artificial Neural Networks (ANN) Redes neurais artificiais utilizadas para modelar padrões complexos e não lineares em dados, sendo amplamente aplicadas na previsão de secas devido à sua capacidade de aprendizagem e generalização. [14](#)

Auto-Regressive Integrated Moving Average (ARIMA) Modelo estatístico usado para séries temporais, que combina componentes autoregressivos e de médias móveis para análise e previsão de padrões climáticos. [14](#), [17](#)

Autoregressive Integrated Moving Average (ARIMA) Classe de modelos de previsão de séries temporais amplamente utilizados para estudar e prever condições de seca com base em padrões históricos. [17](#)

Autoregressive Integrated Moving Average with Exogenous Variables (ARIMAX) Variação do ARIMA que incorpora variáveis exógenas, permitindo a inclusão de fatores externos nos modelos de previsão de séries temporais. [17](#)

Bayesian Convolutional Neural Network (BCNN) Rede Neural Convolutacional Bayesiana, que combina a robustez das redes convolucionais com a inferência probabilística, permitindo a modelagem de incertezas. [14](#)

Boosted Trees (BT) Método que combina árvores de decisão através de boosting para criar modelos mais robustos e precisos. [16](#)

Bootstrap Aggregating (BG) Método de aprendizado em conjunto que combina previsões de modelos gerados por amostragem bootstrap para melhorar a precisão. [16](#)

Bootstrap Aggregating Trees (BAT) Algoritmo que utiliza árvores de decisão agregadas por bootstrap para reduzir a variância do modelo e aumentar a robustez. [16](#)

Bootstrap Aggregating Trees-Algorithm Optimised Extreme Learning Machine (BAT-ELM) Extensão do BAT que integra o Algoritmo Otimizado de Máquinas de Aprendizado Extremo para maior eficiência em aprendizado em conjunto. [16](#)

Cemaden Centro Nacional de Monitoramento e Alertas de Desastres Naturais. Órgão do governo brasileiro criado em 2011, responsável pelo monitoramento e emissão de alertas de desastres naturais, como secas, inundações e deslizamentos. O Cemaden utiliza dados meteorológicos, hidrológicos e geotécnicos, combinados com modelagem computacional e inteligência artificial, para fornecer informações estratégicas para a gestão de riscos e a redução de impactos socioeconômicos. [2](#)

Combined Drought Indicator (CDI) Indicador combinado que integra dados de seca meteorológica, agrícola e hidrológica. O CDI utiliza variáveis como precipitação, umidade do solo e disponibilidade de água para fornecer uma visão abrangente das condições de seca, sendo uma ferramenta valiosa para monitoramento e tomada de decisão em gestão hídrica e agrícola. [13](#)

Convolutional Neural Network (CNN) Rede Neural Convolutacional, amplamente utilizada para análise de dados espaciais e temporais, como imagens e séries temporais. [14](#)

Crop Moisture Index (CMI) Índice de umidade da cultura usado para avaliar condições de seca ou excesso de umidade, baseado no balanço hídrico semanal em relação às necessidades das culturas agrícolas. [9](#)

Decision Trees (DT) Árvores de decisão, um método de aprendizado supervisionado usado para classificação e regressão, reconhecido por sua simplicidade e capacidade de interpretar relações entre variáveis. [14](#), [16](#)

Deep Belief Network (DBN) Rede de Crença Profunda, uma arquitetura composta por camadas empilhadas de redes neurais não supervisionadas, utilizada para aprendizado de representações. [15](#)

Deep Learning (DL) Aprendizado Profundo, uma abordagem baseada em redes neurais profundas para aprendizado hierárquico e análise de grandes volumes de dados. [4](#), [15](#)

Descarga ou vazão (Q) Quantidade de água que escoar em um curso d'água por unidade de tempo, influenciada por fatores naturais e antrópicos, sendo essencial para a gestão dos recursos hídricos. [2](#), [5](#), [7](#)

Detrended Fluctuation Analysis (DFA) Método utilizado para detectar padrões de correlação em séries temporais, frequentemente aplicado em dados climáticos. [17](#)

Discrete Wavelet Transform Neural Network (DWT-ANN) Rede Neural com Transformada Wavelet Discreta, que combina a análise wavelet com redes neurais para modelagem de sinais e séries temporais. [15](#)

Drought Area Index (DAI) Índice utilizado para medir a extensão espacial da seca em uma região, calculado com base na porcentagem de área afetada por condições de seca. [9](#)

Drought Reconnaissance Index (DRI) Índice utilizado para avaliar condições de seca com base no balanço hídrico de uma região, considerando precipitação e evapotranspiração. [9](#)

Duração Número de dias, meses ou intervalos de tempo durante os quais o evento de seca persiste. Secas mais longas tendem a se propagar mais no ciclo hidrológico, aumentando os efeitos secundários. [5](#)

Effective Drought Index (EDI) Índice que avalia a eficiência da precipitação em atender as necessidades hídricas de uma região, comparando dados acumulados com médias históricas. [9](#)

Enhanced Vegetation Index (EVI) Índice derivado de sensoriamento remoto que avalia a densidade e a saúde da vegetação, utilizado para monitoramento ambiental e análise de secas. É calculado a partir das bandas espectrais do vermelho, infravermelho próximo e azul. [12](#)

Ensemble Método de aprendizado que combina múltiplos modelos de previsão para aumentar a precisão, como bagging, boosting e random forests. [14](#), [16](#)

- Estimation of Distribution Algorithm-Extreme Learning Machine (EDA-ELM)** Modelo híbrido que combina algoritmos de estimativa de distribuição com aprendizado extremo para melhorar a precisão das previsões. [17](#)
- Evaporative Stress Index (ESI)** Índice baseado em sensoriamento remoto que avalia o estresse hídrico da vegetação, derivado da relação entre evapotranspiração real e potencial. Amplamente utilizado para monitoramento de secas em tempo quase real. [12](#)
- Evaporação** Processo físico de mudança de fase da água do estado líquido para o gasoso, essencial no ciclo hidrológico e influenciado por variáveis meteorológicas como temperatura, umidade e vento. [7](#)
- Evapotranspiration Deficit Index (ETDI)** Índice utilizado para avaliar o déficit de evapotranspiração em áreas agrícolas, calculado com base na diferença entre a evapotranspiração potencial (ET_p) e a evapotranspiração real (ET_r). [10](#)
- Evapotranspiração** Processo combinado de evaporação da água do solo e da vegetação úmida, juntamente com a transpiração das plantas, responsável pela transferência de vapor d'água da superfície terrestre para a atmosfera. [3](#), [5](#), [6](#), [8](#)
- Evapotranspiração de Referência (ETR)** Taxa de evapotranspiração de uma cultura de referência hipotética com altura de 0,12 m, resistência da superfície de $70 \text{ s } m^{-1}$ e albedo de 0,23, sem limitação hídrica. [7](#)
- Evapotranspiração Potencial (ETP)** Taxa máxima de evapotranspiração de uma superfície completamente coberta por vegetação de altura uniforme, sem restrições hídricas e sem efeitos de advecção ou armazenamento de calor. Indicador da capacidade de secamento do clima. [6](#), [7](#)
- Evapotranspiração Real (ETR)** Taxa efetiva de evapotranspiração considerando a disponibilidade hídrica no solo, sendo sempre menor ou igual à evapotranspiração potencial ($ETR \leq ETP$). [7](#)
- Extreme Gradient Boosting (XGBoost)** Uma versão avançada e eficiente do gradiente boosting, amplamente utilizada em competições de aprendizado de máquina. [16](#)
- Extreme Learning Machine (ELM)** Algoritmo de aprendizado de máquina eficiente e rápido, utilizado para tarefas de classificação e regressão. [17](#)
- Extremely Randomized Trees ET** Método que gera árvores de decisão altamente randomizadas para capturar variabilidade nos dados. [16](#)
- Fim** Indica a retomada das condições normais, incluindo produtividade agrícola e de ecossistemas naturais, recuperação dos níveis de lagos e reservatórios e estabilização das condições socioeconômicas. [3](#), [5](#)

Frequência Número de eventos de seca dentro de um intervalo de tempo definido. Secas mais frequentes podem causar impactos de longo prazo nos ecossistemas e na disponibilidade hídrica. [5](#)

Fuzzy Rule-Based System (FRBS) Sistema baseado em regras fuzzy que representa relações complexas entre variáveis por meio de um conjunto de regras lógicas. [16](#)

Gate Recurrent Unit (GRU) Unidade de Portão Recorrente, uma arquitetura de rede neural recorrente eficiente para modelagem de sequências temporais. [15](#)

Gaussian Process (GP) Modelo estatístico que define distribuições probabilísticas sobre funções para previsão e análise de incertezas. [18](#)

Gaussian Process Regression (GPR) Extensão do GP para tarefas de regressão, permitindo previsões com estimativa de incertezas. [18](#)

Gene-Random Forest (GeRF) Uma extensão das florestas aleatórias que incorpora técnicas genéticas para melhorar a performance do modelo. [16](#)

General Regression Neural Network (GRNN) Rede Neural de Regressão Geral, utilizada para modelagem de relações complexas entre variáveis com alta precisão. [15](#)

Genetic Algorithm-Extreme Learning Machine (GA-ELM) Integra aprendizado extremo com algoritmos genéticos para otimização de parâmetros e aumento da eficiência. [17](#)

Genetic Algorithm-Multilayer Perceptron (GA-MLP) Modelo que combina o Algoritmo Genético com o Perceptron Multicamadas para otimização de parâmetros e desempenho. [15](#)

Genetic Expression Programming (GEP) Método baseado em algoritmos genéticos para geração de modelos de previsão altamente interpretáveis. [17](#)

Global Integrated Drought Monitoring and Prediction System (GIDMaPS) Sistema global que integra monitoramento e previsão de secas, combinando dados observacionais, modelagem e índices padronizados. Oferece mapas globais para avaliar a variabilidade das secas em diferentes escalas temporais e espaciais, sendo uma ferramenta valiosa para gestão de recursos e planejamento estratégico. [13](#)

Global Land Data Assimilation System (GLDAS) Sistema global que integra dados de observação e modelagem para monitorar variáveis do ciclo hidrológico, como umidade do solo, evapotranspiração e balanço hídrico. O GLDAS é amplamente usado para análises de secas e estudos climáticos em escala global, fornecendo dados consistentes e de alta resolução espacial e temporal. [13](#)

Gradient Boosting Machine (GBM) Algoritmo de aprendizado em conjunto que otimiza gradualmente o desempenho do modelo através de boosting. [16](#)

Inteligência Artificial (IA) Campo da ciência da computação que desenvolve sistemas e algoritmos capazes de simular a capacidade humana de aprendizado, raciocínio e tomada de decisão. Na previsão e monitoramento de secas, a IA é aplicada para análise de grandes volumes de dados climáticos, modelagem preditiva e otimização de processos. [3](#), [4](#)

Intensidade A magnitude da seca dividida pela sua duração. Esse indicador caracteriza o potencial geral de impactos do evento de seca. [5](#)

Interrupção Momento em que os índices meteorológicos voltam ao normal, a umidade do solo se recupera e há reestabelecimento do crescimento da vegetação e dos níveis de água nos reservatórios e lagos. [5](#)

Início O primeiro dia, mês ou intervalo de tempo no qual o indicador de seca está abaixo de um determinado limite dependente do tempo. Esse indicador é relevante para identificar períodos críticos, como épocas de semeadura e floração. [3](#), [5](#)

K-means Algoritmo de agrupamento que particiona os dados em k clusters baseados na similaridade dos atributos. [3](#), [18](#)

Kalman filter regression-based Online Sequential Extreme Learning Machine (KOSELM) Kalman filter regression-based Online Sequential Extreme Learning Machine - Modelo que combina filtros de Kalman com aprendizado sequencial extremo para melhorar a precisão em tempo real. [18](#)

Land Surface Water Index (LSWI) Índice que combina informações de vegetação e água, usado para detectar a presença de água na superfície e monitorar a umidade do solo. [13](#)

Lasso Regression (LR) Método de regressão que aplica regularização L1 para melhorar a previsibilidade e evitar overfitting. [18](#)

Least-Square Support Vector Machine (LSSVM) Variação do SVM que utiliza mínimos quadrados para reduzir a complexidade computacional e aumentar a eficiência. [17](#)

Least-Square SVR (LS-SVR) Versão otimizada para regressão do LSSVM, projetada para prever valores contínuos de forma eficiente. [17](#)

Light Gradient Boosting Machine (LGBM) Uma versão otimizada e eficiente do GBM, ideal para conjuntos de dados grandes. [16](#)

Long-Short Term Memory Network (LSTM) Rede de Memória de Curto e Longo Prazo, amplamente utilizada para modelagem de dependências temporais de longo alcance em séries temporais. [15](#), [17](#)

M5Pruned (M5P) Uma versão podada do algoritmo M5, projetada para melhorar a generalização do modelo ao remover ramificações desnecessárias da árvore de decisão. [16](#)

M5Tree (M5T) Uma variação do modelo M5 que utiliza critérios específicos para dividir os dados e construir árvores de decisão otimizadas. [16](#)

Magnitude A gravidade de um evento de seca, relacionada ao déficit hídrico. Calculada como a soma das diferenças, em valores absolutos, entre os valores do indicador de seca (DI) e o limite usado para definir o nível de seca: $S_i = \sum |DI_i| < threshold$. [3](#), [5](#)

Medição de chuva Processo de quantificação da precipitação por meio de diferentes tecnologias, incluindo radares meteorológicos e satélites. [6](#)

Multilayer Perceptron (MLP) Perceptron Multicamadas, uma arquitetura de rede neural composta por camadas de entrada, ocultas e saída, amplamente utilizada na modelagem de padrões complexos. [14](#)

Multilayer Perceptron with Extended Kalman Filter (MLP-EKF) Perceptron Multicamadas combinado com Filtro de Kalman Estendido, utilizado para aprendizado em sistemas dinâmicos não lineares. [15](#)

Multiple Linear Regression (MLR) Técnica estatística que modela a relação linear entre uma variável dependente e várias independentes. [18](#)

Multivariate Standardized Drought Index (MSDI) Índice multivariado que combina variáveis climáticas e hidrológicas, como precipitação, umidade do solo e fluxo de rios, para avaliar secas de forma abrangente. A abordagem multivariada do MSDI permite uma análise robusta e detalhada das condições de seca, considerando interações entre diferentes componentes do sistema climático e hidrológico. [13](#)

Mês de Pico Dia ou mês em que o indicador de seca atinge seu menor valor. Esse período costuma ser o de maior impacto para os sistemas afetados. [5](#)

Naive Bayes (NB) Classificador probabilístico baseado no Teorema de Bayes, amplamente utilizado em aprendizado supervisionado. [18](#)

NOAA Drought Index (NDI) Índice desenvolvido pela NOAA que combina variáveis climáticas como precipitação, temperatura e evapotranspiração para avaliar as condições de seca, fornecendo uma visão abrangente da intensidade, duração e extensão espacial do fenômeno. [9](#)

Nonlinear Auto-Regressive (NAR) Modelo de séries temporais que utiliza valores passados para prever o estado futuro de sistemas não lineares. [18](#)

Nonlinear Auto-Regressive with Exogenous (NARX) Extensão do NAR que inclui variáveis exógenas para melhorar as previsões em sistemas complexos. [18](#)

Normalized Difference Vegetation Index (NDVI) Índice derivado de dados de sensoriamento remoto que mede a densidade e a saúde da vegetação com base na refletância no infravermelho próximo e no vermelho visível. [12](#), [13](#)

Normalized Difference Water Index (NDWI) Índice utilizado para detectar a presença de água na superfície terrestre, combinando bandas verde e infravermelha próxima. [13](#)

Online Sequential Extreme Learning Machine (OSELM) Versão sequencial do ELM, permitindo atualizações em tempo real para previsão de dados em fluxo. [18](#)

Ordinary Least Squares (OLS) Método de regressão linear que minimiza a soma dos erros quadrados para ajustar o modelo. [18](#)

Outras Classes Abrange uma variedade de modelos avançados utilizados para previsão de secas, incluindo técnicas estatísticas, de aprendizado de máquina e híbridas. [17](#)

Palmer Drought Severity Index (PDSI) Índice de seca baseado no balanço hídrico, que leva em consideração a precipitação, a evapotranspiração e a capacidade do solo de reter umidade. É utilizado para monitorar a severidade da seca e é amplamente utilizado em estudos de longo prazo. [9](#), [11](#), [12](#)

Palmer Hydrological Drought Severity Index (PHDI) Índice hidrológico derivado do Palmer Drought Severity Index (PDSI), projetado para avaliar déficits hídricos acumulados em sistemas hidrológicos, como rios e reservatórios. [11](#)

Percent of Normal Precipitation (PNP) Índice que compara a precipitação observada com a precipitação média ou normal para um determinado período. O valor é expresso como uma porcentagem. [9](#)

Precipitação (P) Quantidade de água que atinge a superfície terrestre sob diversas formas (chuva, neve, granizo, etc.), sendo o principal input do sistema hidrológico e o fator desencadeador de processos como escoamento superficial, infiltração e recarga de aquíferos. Apresenta alta variabilidade espacial e temporal, sendo um dado essencial para o monitoramento de secas e o planejamento de recursos hídricos. [2](#), [3](#), [5](#), [6](#), [8](#)

Radares meteorológicos Sensores ativos que utilizam ondas de rádio para detectar e monitorar precipitação, permitindo estimar sua intensidade e movimento. [6](#)

Radial Basis Function Neural Network (RBFNN) Rede Neural com Função de Base Radial, conhecida por sua capacidade de interpolar dados e modelar funções complexas. [15](#)

Radiação solar Energia emitida pelo Sol e recebida pela Terra, fundamental para a variação da temperatura e os processos climáticos e hidrológicos. [6](#)

Random Forest (RF) Uma técnica de aprendizado em conjunto que combina várias árvores de decisão para melhorar a precisão e evitar o overajuste. [16](#)

Random Subspace (RS) Método que utiliza subconjuntos aleatórios de atributos para treinar modelos de aprendizado em conjunto. [16](#)

Random Tree (RT) Método que cria árvores de decisão aleatórias, priorizando simplicidade e robustez. [16](#)

Recurrent Neural Network (RNN) Rede Neural Recorrente, projetada para processar dados sequenciais, como séries temporais e texto. [15](#)

Reduced Error Pruning Tree (REPT) Árvore de Decisão com Poda por Erro Reduzido, projetada para evitar o overajuste removendo ramificações que não contribuem significativamente para o desempenho do modelo. [16](#)

Satélites Plataformas orbitais equipadas com sensores capazes de estimar a precipitação por meio da detecção de radiação visível, infravermelha e micro-ondas. [3](#), [6](#)

Seca Agrícola Refere-se à redução da umidade do solo abaixo dos níveis necessários para o crescimento saudável das culturas. É influenciada tanto pela precipitação reduzida quanto pelo aumento da evapotranspiração, afetando diretamente a produtividade agrícola (Keyantash e Dracup 2002). [2](#), [8](#), [10](#)

Seca Hidrológica Ocorre quando há uma redução persistente no nível de rios, lagos, reservatórios e aquíferos devido a déficits prolongados de precipitação. Afeta a disponibilidade de água para consumo humano, industrial e energético (Ashok K Mishra e Singh 2010b). [2](#), [8](#), [11](#)

Seca Meteorológica Condição caracterizada por um período prolongado de precipitação abaixo da média climatológica, resultando em um déficit hídrico na atmosfera. Esse tipo de seca é geralmente identificado com base em anomalias de precipitação ao longo do tempo (D. A. Wilhite 2000). [2](#), [8](#)

Sensoriamento Remoto (SR) Tecnologia que permite a obtenção de informações sobre a superfície terrestre sem contato direto, por meio da captura e análise de imagens e sinais adquiridos por satélites, drones e sensores aerotransportados. No monitoramento de secas, é fundamental para a estimativa de variáveis ambientais, como cobertura vegetal, umidade do solo e temperatura da superfície. [3](#)

Soil Moisture Anomaly (SMA) Índice usado para avaliar a anomalia da umidade do solo, calculado pela diferença entre a umidade atual do solo e a média histórica do mesmo período. [10](#)

Soil Moisture Deficit Index (SMDI) Índice que avalia o déficit de umidade do solo com base em medições contínuas, permitindo monitorar o impacto da seca agrícola em diferentes profundidades do solo. [3](#), [11](#)

Soil Water Storage (SWS) Métrica que quantifica o total de água armazenada no solo, essencial para avaliar a disponibilidade hídrica e monitorar condições de seca. [11](#)

Standardized Anomaly Index (SAI) Índice utilizado para quantificar a anomalia de variáveis climáticas, como precipitação ou temperatura, em relação à média histórica, sendo útil para identificar secas e outras condições climáticas extremas. [10](#)

Standardized Precipitation Evapotranspiration Index (SPEI) Índice que combina precipitação e evapotranspiração para avaliar a intensidade da seca, considerando tanto a oferta quanto a demanda de água. O SPEI é uma versão aprimorada do Standardized Precipitation Index (SPI), proporcionando uma medida mais precisa da seca. [10](#)

Standardized Precipitation Index (SPI) Índice padronizado utilizado para avaliar a severidade de seca, baseado na precipitação acumulada. O SPI compara a precipitação observada com a média histórica, permitindo medir o déficit ou excedente de umidade. [2](#), [8](#), [10–14](#)

Standardized Reservoir Supply Index (SRSI) Índice padronizado que monitora o armazenamento de água em reservatórios, comparando os níveis atuais com as médias históricas para identificar condições de seca hidrológica. [11](#)

Standardized Streamflow Index (SSFI) Índice padronizado que avalia as condições de seca hidrológica com base na vazão de água em rios e córregos, comparando os níveis observados com a média histórica. [11](#)

Standardized Water-level Index (SWI) Índice padronizado que monitora os níveis de água em reservatórios ou aquíferos, comparando os níveis atuais com a média histórica para identificar condições de seca hidrológica. [12](#)

Streamflow Drought Index (SDI) Índice que mede condições de seca hidrológica com base na análise estatística do fluxo de rios, comparando o fluxo acumulado em um período específico com a média histórica. [3](#), [11](#)

Support Vector Machine (SVM) Classe de algoritmos de aprendizado supervisionado projetada para tarefas de classificação e regressão, com ampla aplicação no estudo de secas. [17](#)

Support Vector Machine Regression (SVMR) Aplicação direta do SVM em problemas de regressão, com alta capacidade de generalização. [17](#)

Support Vector Machine-Grey Wolf Optimizer (SVR-GWO) Modelo híbrido que combina o SVM com o Otimizador do Lobo Cinzento para melhorar a precisão em tarefas complexas. [17](#)

Support Vector Machine-Spotted Hyena Optimizer (SVR-SHO) Modelo híbrido que integra o SVM com o Otimizador da Hiena Pintada, aumentando a capacidade de análise em cenários desafiadores. [17](#)

Support Vector Machines (SVM) Máquinas de vetores de suporte, um método de aprendizado supervisionado usado para classificação e regressão, reconhecido por sua eficiência em lidar com dados de alta dimensionalidade. [14](#), [17](#)

Support Vector Regressor (SVR) Método de regressão baseado em vetores de suporte, que encontra uma função de previsão ótima para dados complexos. [17](#)

Surface Water Supply Index (SWSI) Índice que avalia as condições de seca hidrológica, focando na disponibilidade de água de superfície, como rios e reservatórios, comparando os níveis de água atuais com a média histórica. [12](#)

Temperatura (T) Medição do grau de calor ou frio da atmosfera, influenciada por fatores geográficos como latitude, altitude, distribuição de terras e oceanos, vegetação e circulação atmosférica. [5](#), [6](#), [8](#)

Temperature Condition Index (TCI) Índice utilizado para monitorar o impacto do estresse térmico na vegetação, baseado na comparação da temperatura da superfície terrestre com máximas e mínimas históricas. [12](#)

Umidade do Solo (US) Quantidade de água armazenada nos poros do solo em um determinado momento. Variável essencial para o balanço hídrico, influenciando processos como evapotranspiração, recarga de aquíferos e crescimento vegetal [2](#), [3](#), [7](#)

Umidade Relativa (UR) Razão entre a quantidade de vapor d'água presente no ar e a quantidade máxima que o ar pode conter a uma determinada temperatura, expressa em porcentagem. Influencia diretamente os processos de evapotranspiração e formação de nuvens [7](#)

USDM (United States Drought Monitor) Sistema de monitoramento que avalia as condições de seca nos Estados Unidos com base em dados climáticos, hidrológicos e observações de especialistas. Gera mapas semanais de seca classificados em categorias, servindo como uma ferramenta essencial para decisões políticas, alocação de recursos e estratégias de resposta a desastres. [14](#)

Variação da temperatura (ΔT) Mudanças na temperatura ao longo do tempo, podendo ocorrer em escalas diárias, sazonais e interanuais, influenciadas por fatores climáticos e geográficos. [6](#)

Variações sazonais Mudanças periódicas nas condições climáticas ao longo do ano, influenciadas pela inclinação do eixo terrestre, duração do dia e padrões de insolação. [6](#)

Vegetation Condition Index (VCI) Índice utilizado para avaliar a saúde da vegetação comparando o NDVI atual com valores históricos, útil para monitorar o estresse hídrico e a seca. [12](#)

Vegetation Drought Response Index (VegDRI) Índice que combina dados climáticos, ambientais e de vegetação para monitorar a resposta da vegetação à seca, fornecendo informações detalhadas sobre o impacto em diferentes regiões. [12](#)

Vegetation Health Index (VHI) Índice derivado de dados de satélite que combina o Vegetation Condition Index (VCI) e o Temperature Condition Index (TCI) para avaliar a saúde e o vigor da vegetação, particularmente em condições de estresse climático. [13](#)

Velocidade do Vento (VV) Medida da movimentação do ar em determinada direção e intensidade. Influencia a taxa de evaporação e evapotranspiração, afetando o balanço hídrico e a demanda atmosférica por umidade [7](#)

Water Requirement Satisfaction Index (WRSI) Índice usado para avaliar a satisfação hídrica de uma cultura durante sua estação de crescimento, baseado na proporção entre a água disponível e a necessidade hídrica. A versão Geo-spatial utiliza dados de sensoriamento remoto para análises espaciais. [13](#)

Wavelet Artificial Neural Networks (WANN) Redes Neurais Artificiais com Wavelet, que combinam análise wavelet com aprendizado profundo para modelagem avançada de dados. [15](#)

Wavelet Boosting (WB) Técnica que combina wavelets e boosting para melhorar a capacidade do modelo em capturar padrões complexos. [16](#)

Wavelet Extreme Learning Machine (WELM) Combina aprendizado extremo com transformadas wavelet para análise de séries temporais e previsões climáticas. [17](#)

Wavelet Fuzzy (WF) Modelo que aplica transformadas wavelet em conjunto com lógica fuzzy para melhorar a análise e interpretação de padrões complexos de seca. [16](#)

Wavelet Least-Square SVR (WLS-SVR) Modelo que combina transformadas wavelet com o SVR baseado em mínimos quadrados, ideal para análise de séries temporais complexas. [17](#)

Weighted Anomaly Standardized Precipitation Index (WASP) Índice utilizado para avaliar a severidade da seca meteorológica, considerando a precipitação observada e suas anomalias com um fator de peso, que dá maior relevância às anomalias extremas e de maior duração. [10](#)

Weighted Wavelet Fuzzy (WWF) Modelo que combina lógica fuzzy com transformadas wavelet ponderadas para capturar variações temporais e espaciais em dados relacionados à seca. [16](#)

Área Afetada Área ou porcentagem de uma região (ou país) que apresenta valores do indicador de seca abaixo de um determinado limite. Quanto maior a área afetada, maior o impacto sobre os ativos expostos. [4](#)

Índice Integrado de Seca (IIS) Índice desenvolvido para monitorar e avaliar as condições de seca no Brasil. O IIS combina múltiplas variáveis climáticas e hidrológicas, como precipitação, temperatura, umidade do solo e fluxo de rios. Ele é gerado em intervalos de 3 e 6 meses, permitindo uma análise detalhada tanto em curtos quanto em médios prazos. Amplamente utilizado pelo CEMADEN, o IIS auxilia no planejamento de respostas a desastres e na formulação de políticas públicas. 14

Referências

- AghaKouchak, A. et al. (mai. de 2015). «Remote sensing of drought: progress, challenges and opportunities: REMOTE SENSING OF DROUGHT». Em: *Reviews of Geophysics* 53, n/a–n/a. DOI: [10.1002/2014RG000456](https://doi.org/10.1002/2014RG000456).
- Ahmadreza Gandomi, Seyedali Mirjalili (2020). «Spotted Hyena Optimizer: A nature-inspired optimization algorithm». Em: *Neural Computing and Applications* 32, pp. 6363–6377. DOI: [10.1007/s00521-019-04170-1](https://doi.org/10.1007/s00521-019-04170-1).
- Allen, Richard G. et al. (1998). «Crop Evapotranspiration – Guidelines for Computing Crop Water Requirements». Em: *FAO Irrigation and Drainage Paper* 56. URL: <https://www.fao.org/3/x0490e/x0490e00.htm>.
- Alley, William M. (1984). «The Palmer Drought Severity Index: Limitations and Assumptions». Em: *Journal of Applied Meteorology and Climatology* 23.7, pp. 1100–1109. DOI: [10.1175/1520-0450\(1984\)023<1100:TPDSIL>2.0.CO;2](https://doi.org/10.1175/1520-0450(1984)023<1100:TPDSIL>2.0.CO;2).
- Amit, Yali e Donald Geman (1997). «Shape Quantization and Recognition with Randomized Trees». Em: *Neural Computation*. Vol. 9. 7. MIT Press, pp. 1545–1588. DOI: [10.1162/neco.1997.9.7.1545](https://doi.org/10.1162/neco.1997.9.7.1545).
- Anderson, M.C. et al. (2011). «Evaluation of Drought Indices Based on Thermal Remote Sensing of Evapotranspiration over the Continental United States». Em: *Journal of Climate* 24.8, pp. 2025–2044. DOI: [10.1175/2010JCLI3812.1](https://doi.org/10.1175/2010JCLI3812.1). URL: <https://journals.ametsoc.org/view/journals/clim/24/8/2010jcli3812.1.xml>.
- Baldwin, Mark P et al. (2001). «The quasi-biennial oscillation». Em: *Reviews of Geophysics* 39.2, pp. 179–229.
- Baltas, Evangelos (2007). «Spatial distribution of climatic indices in northern Greece». Em: *Meteorological Applications* 14.1, pp. 69–78. DOI: [10.1002/met.7](https://doi.org/10.1002/met.7). URL: <https://rmets.onlinelibrary.wiley.com/doi/10.1002/met.7>.
- Bergman, K. H., P. Sabol e D. Miskus (1988). «Experimental Indices for Monitoring Global Drought Conditions». Em: *Proceedings of the 13th Annual Climate Diagnostics Workshop*. Cambridge, MA: United States Department of Commerce. URL: https://www.droughtmanagement.info/literature/USDC_Experimental_Indices_Monitoring_Global_Drought_Conditions_1988.pdf.
- Bhalme, H. N. e D. A. Mooley (1980). «Large-Scale Droughts/Floods and Monsoon Circulation». Em: *Monthly Weather Review* 108.8, pp. 1197–1211. DOI: [10.1175/1520-0493\(1980\)108<1197:LSDAMC>2.0.CO;2](https://doi.org/10.1175/1520-0493(1980)108<1197:LSDAMC>2.0.CO;2). URL: https://journals.ametsoc.org/view/journals/mwre/108/8/1520-0493_1980_108_1197_lsdamc_2_0_co_2.xml.
- Bhuiyan, Chandrashekhara (2004). «Various Drought Indices for Monitoring Drought Condition in Aravalli Terrain of India». Em: *Proceedings of the XXth ISPRS Conference*. Istanbul, Turkey: International Society for Photogrammetry e Remote Sensing (ISPRS). URL: <http://www.isprs.org/proceedings/XXXV/congress/comm7/papers/243.pdf>.
- Biau, G. e E. Scornet (2016). «A random forest guided tour». Em: *TEST* 25.2, pp. 197–227. DOI: [10.1007/s11749-016-0481-7](https://doi.org/10.1007/s11749-016-0481-7).

- Box, George E. P. e Gwilym M. Jenkins (1970). *Time Series Analysis: Forecasting and Control*. Holden-Day.
- Breiman, Leo (1996). «Bagging Predictors». Em: *Machine Learning* 24.2, pp. 123–140. DOI: [10.1007/BF00058655](https://doi.org/10.1007/BF00058655).
- (2001). «Random Forests». Em: *Machine Learning* 45.1, pp. 5–32. DOI: [10.1023/A:1010933404324](https://doi.org/10.1023/A:1010933404324).
- Briggs, William M e Daniel S Wilks (1996). «Estimating monthly and seasonal distributions of temperature and precipitation using the new CPC long-range forecasts». Em: *Journal of climate* 9.4, pp. 818–826.
- British Columbia Ministry of Agriculture (2015). *Soil Water Storage Capacity and Available Soil Moisture*. http://www2.gov.bc.ca/assets/gov/farming-natural-resources-and-industry/agriculture-and-seafood/agricultural-land-and-environment/soil-nutrients/600-series/619000-1_soil_water_storage_capacity.pdf. Water Conservation Fact Sheet.
- Broomhead, David S. e David Lowe (1988). «Radial basis functions, multi-variable functional interpolation and adaptive networks». Em: *Royal Signals and Radar Establishment Memorandum* 4148, pp. 1–41.
- Brown, Jesslyn F. et al. (2008). «The Vegetation Drought Response Index (VegDRI): A New Integrated Approach for Monitoring Drought Stress in Vegetation». Em: *GIScience & Remote Sensing* 45, pp. 16–46. DOI: [10.2747/1548-1603.45.1.16](https://doi.org/10.2747/1548-1603.45.1.16). URL: <https://www.tandfonline.com/doi/abs/10.2747/1548-1603.45.1.16>.
- Byun, Hi-Ryong e Donald Wilhite (set. de 1999). «Daily Quantification of Drought Severity and Duration». Em: *Journal of Climate* 12, pp. 2747–2756. DOI: [10.1175/1520-0442\(1999\)012<2747:OQODSA>2.0.CO;2](https://doi.org/10.1175/1520-0442(1999)012<2747:OQODSA>2.0.CO;2).
- Camargo, Antonio Pereira de e Paulo Cesar Sentelhas (2011). «Determinação da evapotranspiração por diferentes métodos e sua influência no desenvolvimento da cultura do feijoeiro (*Phaseolus vulgaris* L.)». Em: *Revista Brasileira de Fruticultura* 33.4, pp. 1023–1030. DOI: [10.1590/S0100-29452011000400002](https://doi.org/10.1590/S0100-29452011000400002). URL: <https://www.scielo.br/j/rbf/a/LXpB3FxFvV55YnzMwJvJWqy/>.
- Chang, Tiao J. e Xenia A. Kleopa (1991). «A PROPOSED METHOD FOR DROUGHT MONITORING¹». Em: *JAWRA Journal of the American Water Resources Association* 27.2, pp. 275–281. DOI: <https://doi.org/10.1111/j.1752-1688.1991.tb03132.x>. eprint: <https://onlinelibrary.wiley.com/doi/pdf/10.1111/j.1752-1688.1991.tb03132.x>. URL: <https://onlinelibrary.wiley.com/doi/abs/10.1111/j.1752-1688.1991.tb03132.x>.
- Chen, Lin et al. (out. de 2023). «Artificial intelligence-based solutions for climate change: a review». Em: *Environmental Chemistry Letters* 21.5, pp. 2525–2557. ISSN: 1610-3661. DOI: [10.1007/s10311-023-01617-y](https://doi.org/10.1007/s10311-023-01617-y). URL: <https://doi.org/10.1007/s10311-023-01617-y>.
- Chen, Tianqi e Carlos Guestrin (2016). «XGBoost: A Scalable Tree Boosting System». Em: *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD)*. ACM, pp. 785–794. DOI: [10.1145/2939672.2939785](https://doi.org/10.1145/2939672.2939785).
- Cho, Kyunghyun et al. (2014). «Learning phrase representations using RNN encoder-decoder for statistical machine translation». Em: *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP)*. Association for Computational Linguistics, pp. 1724–1734. DOI: [10.3115/v1/D14-1179](https://doi.org/10.3115/v1/D14-1179).
- Cortes, Corinna (1995). «Support-Vector Networks». Em: *Machine Learning*.
- Cunha, Ana Paula M. A. et al. (out. de 2019). «Extreme Drought Events over Brazil from 2011 to 2019». Em: *Atmosphere* 10 (11), p. 642. ISSN: 2073-4433. DOI: [10.3390/atmos10110642](https://doi.org/10.3390/atmos10110642). URL: <https://www.mdpi.com/2073-4433/10/11/642>.

- Dietterich, Thomas G. (2000). «Ensemble Methods in Machine Learning». Em: *Multiple Classifier Systems* 1857, pp. 1–15. DOI: [10.1007/3-540-45014-9_1](https://doi.org/10.1007/3-540-45014-9_1).
- Disaster Risk Reduction (UNDRR), United Nations Office for (2021). *Special Report Drought 2021*. Geneva: United Nations. ISBN: 9789212320274.
- Doesken, Nolan J. e David Garen (1991). «Drought Monitoring in the Western United States using a Surface Water Supply Index». Em: *Preprints, Seventh Conference on Applied Climatology*. Salt Lake City, UT: American Meteorology Society, pp. 266–269.
- Drucker, Harris et al. (1997). «Support Vector Regression Machines». Em: *Advances in Neural Information Processing Systems (NIPS)* 9, pp. 155–161.
- Duan, Shiheng e Xiurui Zhang (2022). «AutoML-Based Drought Forecast with Meteorological Variables». Em: *arXiv preprint arXiv:2207.07012*.
- Dutra, Emanuel et al. (2014). «Global meteorological drought—Part 2: Seasonal forecasts». Em: *Hydrology and Earth System Sciences* 18.7, pp. 2669–2678. DOI: [10.5194/hess-18-2669-2014](https://doi.org/10.5194/hess-18-2669-2014). URL: <https://hess.copernicus.org/articles/18/2669/2014/>.
- ELTAHIR, ELFATIH A. B. (1992). «Drought frequency analysis of annual rainfall series in central and western Sudan». Em: *Hydrological Sciences Journal* 37.3, pp. 185–199. DOI: [10.1080/02626669209492581](https://doi.org/10.1080/02626669209492581). eprint: <https://doi.org/10.1080/02626669209492581>. URL: <https://doi.org/10.1080/02626669209492581>.
- Epagri (2020). «Análise de Dados de Vazão». Em: *Boletim Técnico*. URL: <https://publicacoes.epagri.sc.gov.br/BT/article/view/1792>.
- Esposito, Francesca, Donato Malerba e Giovanni Semeraro (1997). «Reduced-error pruning». Em: *Computational Intelligence* 13.2, pp. 268–295. DOI: [10.1111/0824-7935.00035](https://doi.org/10.1111/0824-7935.00035).
- Famiglietti, James S. e Matthew Rodell (2008). «Water in the Balance». Em: *Science* 322.5903, pp. 377–378. DOI: [10.1126/science.1163767](https://doi.org/10.1126/science.1163767).
- Ferreira, Cândida (2001). «Gene Expression Programming: A New Adaptive Algorithm for Solving Problems». Em: *Complex Systems* 13.2, pp. 87–129.
- Freund, Yoav e Robert E. Schapire (1997). «A Decision-Theoretic Generalization of On-Line Learning and an Application to Boosting». Em: *Journal of Computer and System Sciences* 55.1, pp. 119–139. DOI: [10.1006/jcss.1997.1504](https://doi.org/10.1006/jcss.1997.1504).
- Friedman, Jerome H. (2001). «Greedy Function Approximation: A Gradient Boosting Machine». Em: *Annals of Statistics* 29.5, pp. 1189–1232. DOI: [10.1214/aos/1013203451](https://doi.org/10.1214/aos/1013203451).
- (2002). «Stochastic Gradient Boosting». Em: *Computational Statistics & Data Analysis* 38.4, pp. 367–378. DOI: [10.1016/S0167-9473\(01\)00065-2](https://doi.org/10.1016/S0167-9473(01)00065-2).
- Fukushima, Kunihiko (1980). «Neocognitron: A Self-organizing Neural Network Model for a Mechanism of Pattern Recognition Unaffected by Shift in Position». Em: *Biological Cybernetics* 36, pp. 193–202. DOI: [10.1007/BF00344251](https://doi.org/10.1007/BF00344251).
- Gao, Wen, Xuebo Zhang e Shuang Liang (2015). «A Bat Algorithm-Based Extreme Learning Machine for Classification». Em: *The Scientific World Journal* 2015, pp. 1–12. DOI: [10.1155/2015/134025](https://doi.org/10.1155/2015/134025).
- Goddard, Lisa M et al. (2001). «Current approaches to season-to-interannual climate prediction». Em: *Journal of Climate* 14.12, pp. 2600–2615. DOI: [10.1175/1520-0442\(2001\)14%3C2600:CASTIC%3E2.0.CO;2](https://doi.org/10.1175/1520-0442(2001)14%3C2600:CASTIC%3E2.0.CO;2).
- Goodfellow, Ian, Yoshua Bengio e Aaron Courville (2016). «Deep Learning». Em: <https://www.deeplearningbook.org/>.

- Gusyeu, Maksim A. et al. (2015). «Drought Assessment in the Pampanga River Basin, the Philippines. Part 1: A Role of Dam Infrastructure in Historical Droughts». Em: *Proceedings of the 21st International Congress on Modelling and Simulation (MODSIM 2015)*. Broadbeach, Queensland, Australia. URL: <https://mssanz.org.au/modsim2015>.
- Guttman, Nathaniel B. (1998). «Comparing the Palmer Drought Index and the Standardized Precipitation Index». Em: *Journal of the American Water Resources Association* 34.1, pp. 113–121. DOI: [10.1111/j.1752-1688.1998.tb05964.x](https://doi.org/10.1111/j.1752-1688.1998.tb05964.x). URL: <https://onlinelibrary.wiley.com/doi/10.1111/j.1752-1688.1998.tb05964.x>.
- Hao, Z. e A. AghaKouchak (2013). «Multivariate Standardized Drought Index: A Multi-Index Parametric Approach for Drought Analysis». Em: *Advances in Water Resources* 57, pp. 12–18. DOI: [10.1016/j.advwatres.2013.03.009](https://doi.org/10.1016/j.advwatres.2013.03.009). URL: <https://www.sciencedirect.com/science/article/abs/pii/S0309170813000562>.
- Hao, Z., A. AghaKouchak et al. (2014). «Global Integrated Drought Monitoring and Prediction System». Em: *Scientific Data* 1, pp. 1–10. DOI: [10.1038/sdata.2014.1](https://doi.org/10.1038/sdata.2014.1). URL: <https://www.nature.com/articles/sdata20141>.
- Hayes, Michael J. (2006). «Drought Indices». Em: *Van Nostrand's Scientific Encyclopedia*. John Wiley & Sons, Ltd. ISBN: 9780471743989. DOI: <https://doi.org/10.1002/0471743984.vse8593>. eprint: <https://onlinelibrary.wiley.com/doi/pdf/10.1002/0471743984.vse8593>. URL: <https://onlinelibrary.wiley.com/doi/abs/10.1002/0471743984.vse8593>.
- Haykin, Simon (2001). «Kalman filtering and neural networks». Em: *John Wiley & Sons*.
- Hinton, Geoffrey E., Simon Osindero e Yee-Whye Teh (2006). «A fast learning algorithm for deep belief nets». Em: *Neural Computation* 18.7, pp. 1527–1554. DOI: [10.1162/neco.2006.18.7.1527](https://doi.org/10.1162/neco.2006.18.7.1527).
- Ho, Tin Kam (1998). «The Random Subspace Method for Constructing Decision Forests». Em: *IEEE Transactions on Pattern Analysis and Machine Intelligence* 20.8, pp. 832–844. DOI: [10.1109/34.709601](https://doi.org/10.1109/34.709601).
- Hochreiter, Sepp e Jürgen Schmidhuber (1997). «Long short-term memory». Em: *Neural Computation* 9.8, pp. 1735–1780. DOI: [10.1162/neco.1997.9.8.1735](https://doi.org/10.1162/neco.1997.9.8.1735).
- Holton, James R e Richard S Lindzen (1972). «An updated theory for the quasi-biennial cycle of the tropical stratosphere». Em: *Journal of the Atmospheric Sciences* 29.6, pp. 1076–1080.
- Hornik, Kurt, Maxwell Stinchcombe e Halbert White (1989). «Multilayer Feedforward Networks are Universal Approximators». Em: *Neural Networks* 2.5, pp. 359–366. DOI: [10.1016/0893-6080\(89\)90020-8](https://doi.org/10.1016/0893-6080(89)90020-8).
- Huang, Guang-Bin, Qin-Yu Zhu e Chee-Kheong Siew (2006). «Extreme learning machine: Theory and applications». Em: *Neurocomputing* 70, pp. 489–501. DOI: [10.1016/j.neucom.2005.12.126](https://doi.org/10.1016/j.neucom.2005.12.126).
- Huete, Alfredo et al. (2002). «Overview of the Radiometric and Biophysical Performance of the MODIS Vegetation Indices». Em: *Remote Sensing of Environment* 83.1, pp. 195–213. DOI: [10.1016/S0034-4257\(02\)00096-2](https://doi.org/10.1016/S0034-4257(02)00096-2). URL: <https://www.sciencedirect.com/science/article/abs/pii/S0034425702000962>.
- Huntingford, Chris et al. (nov. de 2019). «Machine learning and artificial intelligence to aid climate change research and preparedness». Em: *Environmental Research Letters* 14.12, p. 124007. DOI: [10.1088/1748-9326/ab4e55](https://doi.org/10.1088/1748-9326/ab4e55). URL: <https://dx.doi.org/10.1088/1748-9326/ab4e55>.

- IPCC (2023). *Climate Change 2023: Synthesis Report*. Acessado em: URL.
- Jang, J-SR (1993). «ANFIS: adaptive-network-based fuzzy inference system». Em: *IEEE transactions on systems, man, and cybernetics* 23.3, pp. 665–685.
- Johansson, Å et al. (1998). «On the level and origin of seasonal forecast skill in northern Europe». Em: *Journal of the Atmospheric Sciences* 55.1, pp. 103–127.
- Kailath, Thomas (1974). «A View of Three Decades of Linear Filtering Theory». Em: *IEEE Transactions on Information Theory* 20.2, pp. 146–181. DOI: [10.1109/TIT.1974.1055131](https://doi.org/10.1109/TIT.1974.1055131).
- Katz, Richard W. e Michael H. Glantz (1986). «Anatomy of a Rainfall Index». Em: *Monthly Weather Review* 114.4, pp. 764–771. DOI: [10.1175/1520-0493\(1986\)114<0764:AOARI>2.0.CO;2](https://doi.org/10.1175/1520-0493(1986)114<0764:AOARI>2.0.CO;2). URL: https://journals.ametsoc.org/view/journals/mwre/114/4/1520-0493_1986_114_0764_aoari_2_0_co_2.xml.
- Kaur, Amandeep e Sandeep K. Sood (2020). «Deep learning based drought assessment and prediction framework». Em: 57. Publisher: Elsevier B.V, p. 101067. ISSN: 1574-9541. DOI: [10.1016/j.ecoinf.2020.101067](https://doi.org/10.1016/j.ecoinf.2020.101067).
- Ke, Guolin et al. (2017). «LightGBM: A Highly Efficient Gradient Boosting Decision Tree». Em: *Advances in Neural Information Processing Systems 30*. Ed. por I. Guyon et al. Curran Associates, Inc., pp. 3146–3154. URL: <https://proceedings.neurips.cc/paper/2017/file/6449f44a102fde848669bdd9eb6b76fa-Paper.pdf>.
- Keyantash, John e John A. Dracup (2002). «Quantifying Drought: An Evaluation of Drought Indices». Em: *Hydrology and Earth System Sciences* 6.3, pp. 393–409.
- Kogan, Felix N. (1995). «Droughts of the Late 1980s in the United States as Derived from NOAA Polar-Orbiting Satellite Data». Em: *Bulletin of the American Meteorological Society* 76.5, pp. 655–668. DOI: [10.1175/1520-0477\(1995\)076<0655:DOTLIT>2.0.CO;2](https://doi.org/10.1175/1520-0477(1995)076<0655:DOTLIT>2.0.CO;2). URL: https://journals.ametsoc.org/view/journals/bams/76/5/1520-0477_1995_076_0655_dotlit_2_0_co_2.xml.
- (2001). «Operational Space Technology for Global Vegetation Assessments». Em: *Bulletin of the American Meteorological Society* 82.9, pp. 1949–1964. DOI: [10.1175/1520-0477\(2001\)082<1949:OSTFGV>2.3.CO;2](https://doi.org/10.1175/1520-0477(2001)082<1949:OSTFGV>2.3.CO;2). URL: https://journals.ametsoc.org/view/journals/bams/82/9/1520-0477_2001_082_1949_ostfgv_2_3_co_2.xml.
- Lawrence, Mark G. (2005). «The Relationship between Relative Humidity and the Dewpoint Temperature in Moist Air: A Simple Conversion and Applications». Em: *Bulletin of the American Meteorological Society* 86.2, pp. 225–233. DOI: [10.1175/BAMS-86-2-225](https://doi.org/10.1175/BAMS-86-2-225).
- Leal Filho, Walter et al. (2022). «Deploying artificial intelligence for climate change adaptation». Em: *Technological Forecasting and Social Change* 180, p. 121662.
- LeCun, Yann, Yoshua Bengio e Geoffrey Hinton (2015). «Deep Learning». Em: *Nature* 521, pp. 436–444. DOI: [10.1038/nature14539](https://doi.org/10.1038/nature14539).
- Lindzen, Richard S e James R Holton (1968). «A theory of the quasi-biennial oscillation». Em: *Journal of Atmospheric Sciences* 25.6, pp. 1095–1107.
- Liu, WT e RI Negrón Juárez (2001). «ENSO drought onset prediction in northeast Brazil using NDVI». Em: *International Journal of Remote Sensing* 22.17, pp. 3483–3501.

- Loon, Anne F. Van (jul. de 2015). «Hydrological drought explained». Em: *WIREs Water* 2 (4), pp. 359–392. ISSN: 2049-1948. DOI: [10.1002/wat2.1085](https://doi.org/10.1002/wat2.1085). URL: <https://wires.onlinelibrary.wiley.com/doi/10.1002/wat2.1085>.
- Lyon, Bradfield (2004). «The Strength of El Niño and the Spatial Extent of Tropical Drought». Em: *Geophysical Research Letters* 31.21, p. L21204. DOI: [10.1029/2004GL020901](https://doi.org/10.1029/2004GL020901). URL: <https://agupubs.onlinelibrary.wiley.com/doi/10.1029/2004GL020901>.
- MacKay, David JC et al. (1998). «Introduction to Gaussian processes». Em: *NATO ASI series F computer and systems sciences* 168, pp. 133–166.
- MacQueen, J. (1967). «Some methods for classification and analysis of multivariate observations». Em: 1, pp. 281–297.
- Mannocchi, F., Todisco Francesca e Lorenzo Vergni (jan. de 2004). «Agricultural drought: Indices, definition and analysis». Em: *IAHS-AISH Publication*, pp. 246–254.
- McCabe, M. F. et al. (2017). «The future of Earth observation in hydrology». Em: *Hydrology and Earth System Sciences* 21.7, pp. 3879–3914. DOI: [10.5194/hess-21-3879-2017](https://doi.org/10.5194/hess-21-3879-2017). URL: <https://hess.copernicus.org/articles/21/3879/2017/>.
- McKee, Thomas B., Nolan J. Doesken e John Kleist (1993). «The relationship of drought frequency and duration to time scales». Em: *Proceedings of the 8th Conference on Applied Climatology*, pp. 179–184.
- Mishra, AK e VR Desai (2005). «Drought forecasting using stochastic models». Em: *Stochastic environmental research and risk assessment* 19, pp. 326–339.
- Mishra, Ashok K e Vijay P Singh (2010a). «A review of drought concepts». Em: *Journal of Hydrology* 391 (1–2), pp. 202–216. DOI: [http://dx.doi.org/10.1016/j.jhydrol.2010.07.012](https://doi.org/10.1016/j.jhydrol.2010.07.012). URL: <http://www.sciencedirect.com/science/article/pii/S0022169410004257>.
- (2010b). «A review of drought concepts». Em: *Journal of hydrology* 391.1-2, pp. 202–216.
- Mitchell, K. et al. (2004). «The Multi-Institution North American Land Data Assimilation System (NLDAS): Utilizing Multiple GCIP Products and Partners in a Continental Distributed Hydrological Modelling System». Em: *Journal of Geophysical Research* 109, D07S90. DOI: [10.1029/2003JD003823](https://doi.org/10.1029/2003JD003823). URL: <https://agupubs.onlinelibrary.wiley.com/doi/10.1029/2003JD003823>.
- Mo, Kingtse C. e Dennis P. Lettenmaier (2016). «Precipitation Deficit Flash Droughts over the United States». Em: *Journal of Hydrometeorology* 17.4, pp. 1169–1184. DOI: [10.1175/JHM-D-15-0158.1](https://doi.org/10.1175/JHM-D-15-0158.1). URL: https://journals.ametsoc.org/view/journals/hydr/17/4/jhm-d-15-0158_1.xml.
- Modarres, Reza (2007). «Streamflow Drought Time Series Forecasting». Em: *Stochastic Environmental Research and Risk Assessment* 21, pp. 223–233. DOI: [10.1007/s00477-006-0068-1](https://doi.org/10.1007/s00477-006-0068-1). URL: <https://link.springer.com/article/10.1007/s00477-006-0068-1>.
- Montgomery, Douglas C., Elizabeth A. Peck e G. Geoffrey Vining (2012). *Introduction to Linear Regression Analysis*. 5th. John Wiley & Sons. DOI: [10.1002/9781118386088](https://doi.org/10.1002/9781118386088).
- Murtagh, Fionn e Jean-Luc Starck (1995). «Multiscale smoothing for wavelet-based texture analysis». Em: *Computer Vision and Image Understanding* 61.1, pp. 38–49. DOI: [10.1006/cviu.1995.1003](https://doi.org/10.1006/cviu.1995.1003).
- Nalbantis, Ioannis e George Tsakiris (2008). «Assessment of Hydrological Drought Revisited». Em: *Water Resources Management* 23.5, pp. 881–897. DOI: [10.1007/s11269-008-9305-1](https://doi.org/10.1007/s11269-008-9305-1). URL: <https://link.springer.com/article/10.1007/s11269-008-9305-1>.

- Narasimhan, Balaji e Raghavan Srinivasan (2005). «Development and Evaluation of Soil Moisture Deficit Index (SMDI) and Evapotranspiration Deficit Index (ETDI) for Agricultural Drought Monitoring». Em: *Agricultural and Forest Meteorology* 133.1-4, pp. 69–88. DOI: [10.1016/j.agrformet.2005.07.012](https://doi.org/10.1016/j.agrformet.2005.07.012). URL: <https://www.sciencedirect.com/science/article/pii/S016819230500201X>.
- (2007). «Development and evaluation of soil moisture deficit index (SMDI) and evapotranspiration deficit index (ETDI) for agricultural drought monitoring». Em: *Agricultural and Forest Meteorology* 133.1-4, pp. 69–88.
- Nuhfer, Andreas et al. (2020). «A hydrological drought index for Sweden». Em: *Hydrology Research* 51.5, pp. 892–909.
- Oyarzabal, Ricardo e Leonardo Santos (jan. de 2025). «Forecasting Drought Using Machine Learning: a Systematic Literature Review». Em: *Natural Hazards* 21.5, pp. 2525–2557. ISSN: 1610-3661. DOI: [10.1007/s10311-023-01617-y](https://doi.org/10.1007/s10311-023-01617-y). URL: <https://doi.org/10.1007/s10311-023-01617-y>.
- Pai, Ping-Feng e Chih-Shung Lin (2005). «A hybrid ARIMA and support vector machines model in stock price forecasting». Em: *Omega* 33.6, pp. 497–505. DOI: [10.1016/j.omega.2004.07.024](https://doi.org/10.1016/j.omega.2004.07.024).
- Palmer, W. C. (1968). «Keeping Track of Crop Moisture Conditions, Nationwide: The New Crop Moisture Index». Em: *Weatherwise* 21.4, pp. 156–161. DOI: [10.1080/00431672.1968.9932814](https://doi.org/10.1080/00431672.1968.9932814). URL: <https://www.tandfonline.com/doi/abs/10.1080/00431672.1968.9932814>.
- Palmer, Wayne C (1965). *Meteorological drought*. Vol. 30. US Department of Commerce, Weather Bureau.
- Peña, Daniel, George C. Tiao e Ruey S. Tsay (2011). *A Course in Time Series Analysis*. John Wiley & Sons. DOI: [10.1002/9781118031144](https://doi.org/10.1002/9781118031144).
- Peng, C. K. et al. (1994). «Mosaic organization of DNA nucleotides». Em: *Physical Review E* 49, pp. 1685–1689. DOI: [10.1103/PhysRevE.49.1685](https://doi.org/10.1103/PhysRevE.49.1685).
- Phiri, Darius e Justin Morgenroth (2017). «Developments in Landsat Land Cover Classification Methods: A Review». Em: *Remote Sensing* 9.9. ISSN: 2072-4292. DOI: [10.3390/rs9090967](https://doi.org/10.3390/rs9090967). URL: <https://www.mdpi.com/2072-4292/9/9/967>.
- Pierre Geurts, Damien Ernst e Louis Wehenkel (2006). «Extremely randomized trees». Em: *Machine Learning* 63.1, pp. 3–42. DOI: [10.1007/s10994-006-6226-1](https://doi.org/10.1007/s10994-006-6226-1).
- Quinlan, J. Ross (1986). «Induction of decision trees». Em: *Machine learning* 1.1, pp. 81–106. DOI: [10.1023/A:1022643204877](https://doi.org/10.1023/A:1022643204877).
- (1992). «Learning with continuous classes». Em: *Proceedings of the 5th Australian Joint Conference on Artificial Intelligence*, pp. 343–348.
- Rajaei, Taher, Hadi Ebrahimi e Vahid Nourani (2019). «A review of the artificial intelligence methods in groundwater level modeling». Em: *Journal of Hydrology* 572, pp. 336–351. ISSN: 0022-1694. DOI: <https://doi.org/10.1016/j.jhydrol.2018.12.037>. URL: <https://www.sciencedirect.com/science/article/pii/S002216941930006X>.
- Reichstein, Markus et al. (2019). «Deep learning and process understanding for data-driven Earth system science». Em: *Nature* 566.7743, pp. 195–204.
- Rumelhart, David E., Geoffrey E. Hinton e Ronald J. Williams (1986). «Learning representations by back-propagating errors». Em: *Nature* 323, pp. 533–536. DOI: [10.1038/323533a0](https://doi.org/10.1038/323533a0).
- Santos, Maria Alzira (1983). «Regional droughts: A stochastic characterization». Em: *Journal of Hydrology* 66.1, pp. 183–211. ISSN: 0022-1694. DOI: [https://doi.org/10.1016/0022-1694\(83\)90185-3](https://doi.org/10.1016/0022-1694(83)90185-3). URL: <https://www.sciencedirect.com/science/article/pii/S0022169483901853>.
- Seber, George A. F. e Alan J. Lee (2003). *Linear Regression Analysis*. 2nd. John Wiley & Sons. DOI: [10.1002/0471722199](https://doi.org/10.1002/0471722199).

- Sepulcre-Canto, Guido et al. (2012). «Development of a Combined Drought Indicator to Detect Agricultural Drought in Europe». Em: *Natural Hazards and Earth System Sciences* 12, pp. 3519–3531. DOI: [10.5194/nhess-12-3519-2012](https://doi.org/10.5194/nhess-12-3519-2012). URL: <https://nhess.copernicus.org/articles/12/3519/2012/>.
- Seyedali Mirjalili Seyed Mohammad Mirjalili, Andrew Lewis (2014). «Grey Wolf Optimizer». Em: *Advances in Engineering Software* 69, pp. 46–61. DOI: [10.1016/j.advengsoft.2013.12.007](https://doi.org/10.1016/j.advengsoft.2013.12.007).
- Sheffield, Justin et al. (2014). «A drought monitoring and forecasting system for sub-Sahara African water resources and food security». Em: *Bulletin of the American Meteorological Society* 95.6, pp. 861–882. DOI: [10.1175/BAMS-D-12-00124.1](https://doi.org/10.1175/BAMS-D-12-00124.1). URL: <https://journals.ametsoc.org/view/journals/bams/95/6/bams-d-12-00124.1.xml>.
- Shuttleworth, W. J. (2006). «Evapotranspiration». Em: *Encyclopedia of Hydrological Sciences*. Ed. por M. G. Anderson e J. J. McDonnell. John Wiley & Sons. DOI: [10.1002/0470848944.hsa066](https://doi.org/10.1002/0470848944.hsa066).
- Siegelmann, Hava T, Bill G Horne e C Lee Giles (1997). «Computational capabilities of recurrent NARX neural networks». Em: *IEEE Transactions on Systems, Man, and Cybernetics, Part B (Cybernetics)* 27.2, pp. 208–215.
- Silva, F. A. M., C. A. C. dos Santos e R. M. Silva (2015). «Análise Estatística e Geoestatística da Precipitação Média para o Estado de Alagoas». Em: *Revista Brasileira de Meteorologia* 30.3, pp. 311–324. DOI: [10.1590/0102-778620130093](https://doi.org/10.1590/0102-778620130093). URL: <https://www.scielo.br/j/rbmet/a/3sv8mPctrRqbcsvdrFKZPGG/>.
- Silva, J. A. (2008). «Considerações sobre o conceito de temperatura e energia térmica molar». Em: *Revista Brasileira de Ensino de Física* 30.1, pp. 1302-1–1302-5. DOI: [10.1590/S1806-11172008000100002](https://doi.org/10.1590/S1806-11172008000100002). URL: <https://www.scielo.br/j/rbef/a/5nqXgLsznmNJkc4yRbQjHdK/?lang=pt>.
- Soori, Mohsen, Behrooz Arezoo e Roza Dastres (2023). «Artificial intelligence, machine learning and deep learning in advanced robotics, a review». Em: *Cognitive Robotics* 3, pp. 54–70.
- Specht, Donald F. (1991). «A general regression neural network». Em: *IEEE Transactions on Neural Networks* 2.6, pp. 568–576. DOI: [10.1109/72.97934](https://doi.org/10.1109/72.97934).
- Strommen, Norton D. e Raymond P. Motha (1987). «An Operational Early Warning Agricultural Weather System». Em: *Planning for Drought: Toward a Reduction of Societal Vulnerability*. Ed. por D. A. Wilhite, W. E. Easterling e D. A. Wood. Boulder, CO: Westview Press, pp. 153–164. URL: <https://www.taylorfrancis.com/chapters/edit/10.4324/9780429301735-12/operational-early-warning-agricultural-weather-system-norton-strommen-raymond-motha>.
- Suykens, Johan A.K., Tony Van Gestel et al. (2002). *Least Squares Support Vector Machines*. World Scientific. DOI: [10.1142/9789812777480](https://doi.org/10.1142/9789812777480).
- Suykens, Johan A.K. e Joos Vandewalle (1999). «Least squares support vector machine classifiers». Em: *Neural Processing Letters* 9, pp. 293–300. DOI: [10.1023/A:1018628609742](https://doi.org/10.1023/A:1018628609742).
- Svoboda, Mark e Brian Fuchs (2016). *Handbook of Drought Indicators and Indices*. Geneva: Integrated Drought Management Programme (IDMP) e World Meteorological Organization (WMO). ISBN: 9789263111739.

- Svoboda, Mark, David Lecomte et al. (2002). «The Drought Monitor». Em: *Bulletin of the American Meteorological Society* 83.8, pp. 1181–1190. DOI: [10.1175/1520-0477-83.8.1181](https://doi.org/10.1175/1520-0477-83.8.1181). URL: https://journals.ametsoc.org/view/journals/bams/83/8/1520-0477_2002_083_1181_tdm_2_3_co_2.xml.
- Thorntwaite, C. W. (1948). «An Approach toward a Rational Classification of Climate». Em: *Geographical Review* 38.1, pp. 55–94. DOI: [10.2307/210739](https://doi.org/10.2307/210739). URL: <https://www.jstor.org/stable/210739>.
- Tsakiris, George e Harris Vangelis (2005). «Establishing a Drought Index Incorporating Evapotranspiration». Em: *European Water* 9/10, pp. 3–11. URL: https://www.researchgate.net/publication/267921021_Establishing_a_Drought_Index_Incorporating_Evapotranspiration.
- Van Loon, Anne F (2015). «Hydrological drought explained». Em: *Wiley Interdisciplinary Reviews: Water* 2.4, pp. 359–392.
- Vapnik, Vladimir, Steven E. Golowich e Alex Smola (1996). «Support vector method for function approximation, regression estimation, and signal processing». Em: *Advances in Neural Information Processing Systems (NIPS)* 9, pp. 281–287.
- Verdin, James e Robert Klaver (2002). «Grid-Cell-Based Crop Water Accounting for the Famine Early Warning System». Em: *Hydrological Processes* 16.8, pp. 1617–1630. DOI: [10.1002/hyp.1025](https://doi.org/10.1002/hyp.1025). URL: <https://onlinelibrary.wiley.com/doi/abs/10.1002/hyp.1025>.
- Vicente-Serrano, Sergio M., Santiago Beguería e José I. López-Moreno (2010). «A Multiscalar Drought Index Sensitive to Global Warming: The Standardized Precipitation Evapotranspiration Index». Em: *Journal of Climate* 23.7, pp. 1696–1718. DOI: [10.1175/2009JCLI2909.1](https://doi.org/10.1175/2009JCLI2909.1). URL: <https://journals.ametsoc.org/view/journals/clim/23/7/2009jcli2909.1.xml>.
- Vogt, Jürgen V. et al. (2018). *Drought Risk Assessment and Management: A Conceptual Framework*. Luxembourg: Publications Office of the European Union. DOI: [10.2760/057223](https://doi.org/10.2760/057223). URL: <https://publications.jrc.ec.europa.eu/repository/handle/JRC113937>.
- Wang, Li et al. (2005). «Weighted least squares support vector machines for classification and regression analysis». Em: *Neurocomputing* 68, pp. 975–985. DOI: [10.1016/j.neucom.2004.12.117](https://doi.org/10.1016/j.neucom.2004.12.117).
- Wang, Y. e Ian H. Witten (1997). «Inducing model trees for continuous classes». Em: *European Conference on Machine Learning*, pp. 128–137.
- Webb, Geoffrey I, Eamonn Keogh e Risto Miikkulainen (2010). «Naive Bayes». Em: *Encyclopedia of machine learning* 15.1, pp. 713–714.
- Wegmann, Martin e Fernando Jaume-Santero (jun. de 2023). «Artificial intelligence achieves easy-to-adapt nonlinear global temperature reconstructions using minimal local data». Em: *Communications Earth & Environment* 4.1, p. 217. ISSN: 2662-4435. DOI: [10.1038/s43247-023-00872-9](https://doi.org/10.1038/s43247-023-00872-9). URL: <https://doi.org/10.1038/s43247-023-00872-9>.
- Wen, Jiawen, Zhi-Hua Zhou e Li-Xin Xu (2010). «A hybrid extreme learning machine with genetic algorithm for function approximation problems». Em: *Neurocomputing* 74, pp. 155–163. DOI: [10.1016/j.neucom.2010.07.023](https://doi.org/10.1016/j.neucom.2010.07.023).
- Wiener, Norbert (1949). «Extrapolation, Interpolation, and Smoothing of Stationary Time Series». Em: *MIT Press*. URL: <https://archive.org/details/extrapolationint00wien>.
- Willhite, Donald A. (2000). *Drought: A Global Assessment*. Routledge.
- (2011). *Drought and Water Crises: Science, Technology, and Management Issues*. CRC Press.
- Willhite, Donald A. et al. (2017). «Title of the Article». Em: *Journal Name* Volume Number, Page Numbers. DOI: [DOIifavailable](#).

- Woli, Prem et al. (2012). «Agricultural Reference Index for Drought (ARID)». Em: *Agronomy Journal* 104.2, pp. 287–300. DOI: [10.2134/agronj2011.0286](https://doi.org/10.2134/agronj2011.0286). URL: <https://access.onlinelibrary.wiley.com/doi/10.2134/agronj2011.0286>.
- World AgroMeteorological Information Service (2024). *Global AgroMeteorological Project - Chapter 6*. Accessed: 16-Jan-2025. URL: http://www.wamis.org/agm/gamp/GAMP_Chap06.pdf.
- Yang, Xin-She (2010). «A New Metaheuristic Bat-Inspired Algorithm». Em: *Nature Inspired Cooperative Strategies for Optimization (NICSO)* 284, pp. 65–74. DOI: [10.1007/978-3-642-12538-6_6](https://doi.org/10.1007/978-3-642-12538-6_6).
- Yang, Zhi-Hua, Wei Zhang e Yi-Xian Yang (2013). «Extreme learning machine with estimation of distribution algorithms». Em: *Neurocomputing* 102, pp. 111–123. DOI: [10.1016/j.neucom.2011.12.061](https://doi.org/10.1016/j.neucom.2011.12.061).
- Yao, Xin (1999). «Evolving artificial neural networks». Em: *Proceedings of the IEEE* 87.9, pp. 1423–1447. DOI: [10.1109/5.784219](https://doi.org/10.1109/5.784219).
- Yaseen, Zaher Mundher et al. (2021). «Forecasting standardized precipitation index using data intelligence models: regional investigation of Bangladesh». Em: *Scientific reports* 11.1, p. 3435.
- Zadeh, Lotfi A. (1973). «Outline of a New Approach to the Analysis of Complex Systems and Decision Processes». Em: *IEEE Transactions on Systems, Man, and Cybernetics* SMC-3.1, pp. 28–44. DOI: [10.1109/TSMC.1973.5408575](https://doi.org/10.1109/TSMC.1973.5408575).
- Zargar, A. et al. (2011). «A review of drought indices». Em: *Environmental Reviews* 19.NA, pp. 333–349.
- Zhang, Guoqiang (2003). «Time series forecasting using a hybrid ARIMA and neural network model». Em: *Neurocomputing* 50, pp. 159–175. DOI: [10.1016/S0925-2312\(01\)00702-0](https://doi.org/10.1016/S0925-2312(01)00702-0).
- Zhang, Haigang, Sen Zhang e Yixin Yin (2018). «Kernel online sequential ELM algorithm with sliding window subject to time-varying environments». Em: *Memetic Computing* 10, pp. 43–52.
- Zhang, Jing, Lin Feng e Laihang Yu (2017). «A novel target tracking method based on OSELM». Em: *Multidimensional Systems and Signal Processing* 28, pp. 1091–1108.
- Zhang, Qi et al. (2023). «Spatiotemporal characteristics and forecasting of short-term meteorological drought in China». Em: *Journal of Hydrology* 624, p. 129924. ISSN: 0022-1694. DOI: <https://doi.org/10.1016/j.jhydrol.2023.129924>. URL: <https://www.sciencedirect.com/science/article/pii/S0022169423008661>.
- Zhang, Qinghua e Albert Benveniste (1992). «Wavelet networks». Em: *IEEE Transactions on Neural Networks* 3.6, pp. 889–898. DOI: [10.1109/72.165591](https://doi.org/10.1109/72.165591).
- Zong, Wei, Guang-Bin Huang e Yiqiang Chen (2013). «Weighted extreme learning machine for imbalance learning». Em: *Neurocomputing* 101, pp. 229–242. DOI: [10.1016/j.neucom.2012.08.026](https://doi.org/10.1016/j.neucom.2012.08.026).